AI VIET NAM
@aivietnam.edu.vn

DLinear

Linear, DLinear, NLinear tại nghiệm tối ưu: kiến trúc hay cách huấn luyện?

Hoàng Đinh Tuấn Anh

14/10/2026

Tóm tắt

Bài LTSF-Linear cho thấy các mô hình tuyến tính DLinear và NLinear dự báo chuỗi thời gian dài tốt hơn nhiều mô hình Transformer, nhưng mọi so sánh đều qua huấn luyện bằng SGD. Vì vậy chưa rõ ưu thế đến từ kiến trúc hay từ cách huấn luyện. Chúng tôi thay SGD bằng nghiệm tối ưu tất định: nghiệm dạng đóng cho MSE (OLS, ridge) và bình phương tối thiểu có trọng số lặp lại (IRLS) cho MAE và Huber. Ma trận thí nghiệm gồm 3 mô hình, 3 hàm mục tiêu, 3 dataset ETT và 4 horizon; λ chỉ chọn trên tập kiểm định. Có ba kết quả chính. (1) Tại nghiệm tối ưu, DLinear trùng Linear khi không phạt, và chỉ tách khỏi Linear khi có weight decay. Trên ETTh1, ETTh2, ETTm1 và mọi horizon, MSE test của DLinear và Linear tại λ^* chênh nhau không quá 0,0006. NLinear tách khỏi Linear ở mọi λ, vì ràng buộc tổng hàng bằng 1; ràng buộc này có lợi rõ trên ETTh2. (2) Huấn luyện bằng MAE cho MSE test thấp hơn huấn luyện bằng MSE ở 30/36 ô, và thấp nhất trong ba mục tiêu ở 24 ô. Huber nằm giữa MSE và MAE ở 28/36 ô. MAE bền vững khi outlier chỉ nằm ở đích, nhưng mất lợi thế khi outlier vừa nhiều vừa lớn và nằm cả trong đầu vào. (3) Sau khi tinh chỉnh learning rate, SGD vẫn kém nghiệm dạng đóng trên test ở 27/36 ô (có ý nghĩa thống kê). SGD tốt hơn nghiệm tối ưu chỉ xảy ra trên ETTh2, ở 5 ô, và không giá trị λ nào của ridge đạt được mức đó. Khi cả hai mô hình được tinh chỉnh learning rate, DLinear không còn tốt hơn Linear có ý nghĩa ở ô nào.

Mục lục

Bảng thuật ngữ **4**

I. Giới thiệu **6**

I.1. Bối cảnh 6

I.2. Câu hỏi nghiên cứu 6

I.3. Đóng góp 6

II. Công trình liên quan **7**

III. Phương pháp và thiết lập . . . **7**
III.1. Dữ liệu . . . 7
III.2. Ba mô hình dưới dạng ma trận hiệu dụng . . . 8
III.3. Ba hàm mục tiêu và quy ước λ . . . 8
III.4. Bộ giải . . . 9
III.5. Chọn λ^* . . . 9
III.6. SGD . . . 9
III.7. Outlier nhân tạo . . . 10
III.8. Thống kê và quy tắc đọc ba trường hợp . . . 10

IV. Kết quả . . . **11**
IV.1. RQ1: khi nào DLinear và NLinear thu về Linear . . . 11
IV.2. RQ2: hàm mục tiêu và outlier . . . 13
IV.3. RQ3: SGD so với nghiệm tối ưu . . . 17
IV.4. ETTh2 và các đoạn cảm biến bị kẹt . . . 21

V. Thảo luận . . . **23**

VI. Hạn chế và hướng phát triển . . . **24**

VII. Kết luận . . . **26**

Tài liệu tham khảo . . . **26**

Phụ lục . . . **28**

A. Dẫn xuất ba dự đoán của RQ1 . . . **28**
A.1. Dự đoán 1: DLinear trùng Linear khi $\lambda = 0$ . . . 28
A.2. Dự đoán 2: DLinear tách khỏi Linear khi $\lambda > 0$ . . . 28
A.3. Dự đoán 3: NLinear tách khỏi Linear ở mọi λ . . . 29
A.4. Kiểm bằng module của LTSF-Linear . . . 29

B. IRLS cho MAE và Huber . . . **29**
B.1. Lập luận MM . . . 29
B.2. Các chi tiết cài đặt . . . 30
B.3. Các phép kiểm . . . 30

C. Bảng đầy đủ . . . **31**

C.1. Nghiệm tối ưu, đủ mọi tổ hợp 31
C.2. SGD so với nghiệm dạng đóng, từng ô 33
C.3. Họ ridge trên ETTh2 35
C.4. Vị trí các đoạn hằng của ETTh2 36
C.5. Huber với δ theo từng bước h 36
C.6. Thí nghiệm outlier 37

D. Tái lập 39
D.1. Môi trường và phần cứng 39
D.2. Seed 39
D.3. Lệnh 40
D.4. Thời gian chạy đã đo 40
D.5. Phiên bản 40

Bảng thuật ngữ

Thuật ngữ	Tạm dịch	Mô tả
closed-form solution	nghiệm dạng đóng	Nghiệm tính trực tiếp bằng công thức đại số (OLS, ridge, NLinear có ràng buộc), không lặp.
optimum	nghiệm tối ưu	Điểm cực tiểu toàn cục của hàm mục tiêu trên tập huấn luyện. Với MSE là nghiệm dạng đóng; với MAE, Huber là điểm IRLS hội tụ tới.
objective	hàm mục tiêu	Hàm được cực tiểu khi huấn luyện: MSE, MAE hoặc Huber, cộng phạt $\lambda\|W\|^2$ nếu có.
validation set	tập kiểm định (val)	Dùng để chọn λ, δ, learning rate và epoch. Không bao giờ dùng tập kiểm tra để chọn.
test set	tập kiểm tra (test)	Chỉ dùng để báo cáo sai số cuối.
stuck sensor segment	đoạn cảm biến bị kẹt	Đoạn chuỗi giữ nguyên một giá trị trong thời gian dài (ở ETTh2); cửa sổ có đầu vào hoặc đích hằng.
horizon H	độ dài dự báo	Số bước tương lai cần dự báo: 96, 192, 336, 720.
look-back window L	cửa sổ đầu vào	Số bước quá khứ làm đầu vào; cố định $L = 336$.
ridge	hồi quy phạt L2	Bình phương tối thiểu cộng $\lambda\|W\|^2$; tương đương weight decay.
OLS	bình phương tối thiểu thường	Ridge với $\lambda = 0$.
IRLS	bình phương tối thiểu có trọng số lặp lại	Thuật toán cực tiểu MAE, Huber bằng một chuỗi bài toán bình phương tối thiểu có trọng số; là thuật toán MM nên hàm mục tiêu không tăng.

Thuật ngữ	**Tạm dịch**	**Mô tả**
SGD	gradient ngẫu nhiên	Ở đây là cách huấn luyện của LTSF-Linear: Adam theo mini-batch, dừng sớm theo MSE val.
seed	hạt giống ngẫu nhiên	Quyết định khởi tạo và thứ tự mini-batch của SGD, và vị trí outlier nhân tạo.
learning rate	tốc độ học (lr)	Bước của Adam; được tinh chỉnh ở mục IV.3.
Huber loss	hàm mất mát Huber	Bậc hai khi $\|r\| \leq \delta$, tuyến tính khi $\|r\| > \delta$; nằm giữa MSE và MAE.
outlier	giá trị ngoại lai	Ở đây là điểm được cộng $\pm k$ lần độ lệch chuẩn của kênh trong train.

I. Giới thiệu

I.1. Bối cảnh

Bài LTSF-Linear [1] cho thấy các mô hình tuyến tính một lớp dự báo chuỗi thời gian dài tốt hơn nhiều mô hình Transformer trên các bộ dữ liệu chuẩn. Bài đề xuất hai biến thể của mô hình tuyến tính thuần (Linear). DLinear tách chuỗi đầu vào thành phần xu hướng (trung bình trượt) và phần mùa vụ, rồi dùng một lớp tuyến tính cho mỗi phần. NLinear trừ giá trị cuối của cửa sổ đầu vào trước khi đưa vào lớp tuyến tính, rồi cộng lại sau. Trong các bảng của bài, DLinear và NLinear thường tốt hơn Linear.

Mọi so sánh trong bài gốc đều qua huấn luyện bằng SGD: Adam theo mini-batch [2], dừng sớm theo tập kiểm định (val), mỗi cấu hình một lần chạy. Kết quả vì vậy trộn hai thứ: khả năng biểu diễn của kiến trúc, và những gì quá trình huấn luyện đạt được (learning rate, dừng sớm, seed). Ngoài ra, hàm mục tiêu mặc định là MSE. Chưa có đánh giá hệ thống với MAE và Huber, nhất là khi dữ liệu có outlier.

I.2. Câu hỏi nghiên cứu

Ba mô hình đều tuyến tính theo tham số. Với MSE, nghiệm tối ưu có dạng đóng; với MAE và Huber, hàm mục tiêu lồi và giải được tới hội tụ bằng IRLS. Thay SGD bằng nghiệm tối ưu cho phép tách câu hỏi về kiến trúc khỏi câu hỏi về huấn luyện. Chúng tôi đặt ba câu hỏi:

- **RQ1**: Tại nghiệm tối ưu, khi nào DLinear và NLinear thu về Linear, và khi nào thì không?
- **RQ2**: Hàm mục tiêu (MSE, MAE, Huber) ảnh hưởng thế nào đến sai số test, và mức bền vững với outlier ra sao?
- **RQ3**: Mô hình huấn luyện bằng SGD kém nghiệm tối ưu (OLS, ridge ở λ^*) bao nhiêu, và khoảng cách này thay đổi thế nào theo dataset và horizon?

I.3. Đóng góp

1. Dẫn xuất đại số cho cả ba mô hình dưới dạng một ma trận hiệu dụng W_{eff}, và ba dự đoán cho RQ1. Các dự đoán được kiểm bằng chính module DLinear, NLinear của repo LTSF-Linear (mục IV.1, Phụ lục A).
2. Bộ giải nghiệm tối ưu cho ba hàm mục tiêu: nghiệm dạng đóng cho MSE, nghiệm có ràng buộc cho NLinear, IRLS trên GPU cho MAE và Huber, kèm các phép kiểm hội tụ (Phụ lục B).
3. Ma trận thí nghiệm đầy đủ: 3 mô hình $\times$ 3 mục tiêu $\times$ $\{\lambda = 0, \lambda^*\}$ $\times$ 3 dataset $\times$ 4 horizon, cộng thí nghiệm outlier nhân tạo (mục IV.2).
4. So sánh SGD (nhiều seed, learning rate gốc và đã tinh chỉnh) với nghiệm tối ưu trên 36 ô, kèm khoảng tin cậy và quy tắc đọc ba trường hợp (mục IV.3).
5. Repo tái lập được bằng một lệnh (Phụ lục D).

II. Công trình liên quan

LTSF-Linear. Zeng và cộng sự [1] đặt câu hỏi Transformer có thật sự hiệu quả cho dự báo chuỗi thời gian dài không, và đề xuất Linear, DLinear, NLinear. Các mô hình này dùng chung trọng số cho mọi kênh (`individual = False`). Bộ dữ liệu ETT (nhiệt độ dầu và tải của máy biến áp điện) được giới thiệu cùng mô hình Informer [3]. Chúng tôi dùng đúng cách chia, chuẩn hóa và siêu tham số SGD của repo LTSF-Linear. Số công bố lấy từ Bảng 2 của bài gốc.

Phân tích mô hình tuyến tính cho dự báo chuỗi thời gian. Toner và Darlow [4] xét tập hàm mà mỗi biến thể tuyến tính biểu diễn được (lớp mô hình). Họ chứng minh DLinear có cùng lớp mô hình với Linear, tức mọi ánh xạ affine $\mathbf{x} \mapsto A\mathbf{x} + \mathbf{b}$; FITS cũng vậy khi bỏ bộ lọc thông thấp và độ dài đầu vào $L \geq T - 2$. NLinear tương đương hồi quy tuyến tính với ràng buộc mỗi hàng của ma trận trọng số có tổng bằng 1, hệ số chặn tự do. Linear kèm chuẩn hóa theo từng mẫu (RLinear, FITS+IN) có cùng ràng buộc tổng hàng, nhưng hệ số chặn được nhân với độ lệch chuẩn của cửa sổ đầu vào. Vì bình phương tối thiểu là bài toán lồi, mỗi lớp có nghiệm dạng đóng. Trên 8 bộ dữ liệu và 4 horizon, nghiệm dạng đóng cho MSE test thấp hơn mô hình huấn luyện bằng gradient ở 23/32 cấu hình. Kết luận của họ về DLinear và NLinear khớp với RQ1 của chúng tôi khi dùng MSE và $\lambda = 0$ (mục IV.1). Bài này mở rộng ở ba điểm: với ridge ($\lambda > 0$), phép tham số hóa lại của DLinear làm đổi số hạng phạt, nên DLinear tách khỏi Linear dù cùng lớp mô hình; xét thêm MAE và Huber; và so SGD với nghiệm tối ưu qua nhiều seed, có khoảng tin cậy (RQ3).

Hồi quy bền vững và IRLS. Hàm mất mát Huber [5] bậc hai với phần dư nhỏ và tuyến tính với phần dư lớn, nên ít nhạy với outlier hơn MSE. Hằng số 1,345 cho hiệu quả khoảng 95% dưới nhiễu chuẩn, và $1{,}4826 \cdot \mathrm{MAD}$ là ước lượng bền vững của độ lệch chuẩn [6]. Chúng tôi dùng cả hai để đặt δ (mục III.3). MAE và Huber được cực tiểu bằng bình phương tối thiểu có trọng số lặp lại (IRLS) [7]. Ở đây IRLS được viết dưới dạng thuật toán MM (Phụ lục B).

Dừng sớm và ridge. Với bình phương tối thiểu, gradient descent toàn batch xuất phát từ 0 rồi dừng sớm cho nghiệm gần nghiệm ridge ở một λ tương ứng với thời điểm dừng [8]. Kết quả này là lý do chúng tôi so SGD với ridge ở λ^* chọn trên val, chứ không chỉ với OLS.

Nhiễu đầu vào và chính quy hóa Tikhonov. Huấn luyện với nhiễu cộng vào đầu vào tương đương, ở bậc thấp nhất, với thêm một số hạng chính quy hóa Tikhonov [9]. Chúng tôi chỉ dùng kết quả này để nêu một giả thuyết chưa kiểm ở mục V.

III. Phương pháp và thiết lập

III.1. Dữ liệu

Ba dataset ETTh1, ETTh2 (lấy mẫu theo giờ) và ETTm1 (15 phút), mỗi dataset 7 kênh [3]. ETTh1 và ETTm1 đo cùng một máy biến áp, chỉ khác tần suất lấy mẫu; ETTh2 đo một máy biến áp khác. Vì vậy ba dataset chỉ là hai nguồn dữ liệu độc lập (hạn chế 1). Cách chia giống LTSF-Linear: 12 tháng train, 4 tháng val, 4 tháng test, tức 8640 / 2880 / 2880 hàng với dữ liệu

theo giờ (nhân 4 với ETTm1). Cửa sổ val và test bắt đầu lùi L hàng vào tập trước, để mọi điểm đích đều có đủ đầu vào. Mỗi kênh được chuẩn hóa bằng trung bình và độ lệch chuẩn của train (ddof $= 0$, như `StandardScaler`). Mọi MSE, MAE trong báo cáo tính trên dữ liệu đã chuẩn hóa, lấy trung bình trên mọi phần tử (cửa sổ, kênh, bước h).

Cửa sổ đầu vào dài $L = 336$, horizon $H \in \{96, 192, 336, 720\}$. Như baseline SGD, ba mô hình dùng chung trọng số cho 7 kênh. Mỗi kênh của mỗi cửa sổ là một mẫu (x, y) với $x \in \mathbb{R}^L$, $y \in \mathbb{R}^H$. Xếp các mẫu train thành $X \in \mathbb{R}^{n\times L}$ và $Y \in \mathbb{R}^{n\times H}$.

III.2. Ba mô hình dưới dạng ma trận hiệu dụng

Cả ba mô hình đều là ánh xạ affine $\hat{y} = W_{\text{eff}}x + b$, chỉ khác cách tham số hóa $W_{\text{eff}} \in \mathbb{R}^{H\times L}$.

- **Linear:** $W_{\text{eff}} = W$, tham số tự do.
- **DLinear:** gọi $P \in \mathbb{R}^{L\times L}$ là ma trận trung bình trượt kích thước k của LTSF-Linear (đệm $(k-1)/2$ bản sao giá trị đầu và cuối, rồi lấy trung bình). Phần xu hướng là Px, phần mùa vụ là $(I - P)x$, và

$$\hat{y} = W_t Px + W_s(I - P)x + b, \qquad W_{\text{eff}} = W_t P + W_s(I - P). \tag{1}$$

  Mặc định $k = 25$.
- **NLinear:** trừ giá trị cuối x_L rồi cộng lại,

$$\hat{y} = W(x - x_L\mathbf{1}_L) + x_L\mathbf{1}_H + b, \qquad W_{\text{eff}} = W(I - \mathbf{1}_L e_L^\top) + \mathbf{1}_H e_L^\top. \tag{2}$$

  Vì $(I - \mathbf{1}_L e_L^\top)\mathbf{1}_L = 0$, mọi hàng của W_{eff} có tổng bằng 1: $W_{\text{eff}}\mathbf{1}_L = \mathbf{1}_H$. Ngược lại, mọi W_{eff} thỏa ràng buộc này đều viết được dưới dạng (2). Vì vậy NLinear chính là Linear với ràng buộc tổng hàng bằng 1.

Phụ lục A dùng các biểu diễn này để suy ra ba dự đoán của RQ1.

III.3. Ba hàm mục tiêu và quy ước λ

Với phần dư $r = y - \hat{y}$ trên train, ba hàm mục tiêu viết ở dạng tổng (không chia cho n):

$$\text{MSE:} \quad \textstyle\sum r^2 + \lambda \sum_h w_h^\top \text{Pen}\, w_h, \tag{3}$$

$$\text{MAE:} \quad \textstyle\sum |r| + \lambda \sum_h w_h^\top \text{Pen}\, w_h, \tag{4}$$

$$\text{Huber:} \quad \textstyle\sum \rho_\delta(r)/\delta + \lambda \sum_h w_h^\top \text{Pen}\, w_h, \qquad \rho_\delta(r) = \begin{cases} r^2/2 & |r| \le \delta \\ \delta(|r| - \delta/2) & |r| > \delta \end{cases} \tag{5}$$

với w_h là hàng h của W_{eff}. Bias không bị phạt. Chia Huber cho δ để khi $\delta \to 0$ ta được đúng MAE. Bộ giải dùng Huber với $\delta = 10^{-6}$ cho MAE. Với MSE, phạt trên tổng tương ứng `weight_decay` $\approx 2\lambda/(nH)$ của PyTorch khi loss là MSE trung bình.

Hàm phạt của từng mô hình. Weight decay của PyTorch phạt các tham số của module, nên hàm phạt tương ứng trên W_{eff} khác nhau giữa ba mô hình:

- Linear: Pen $= I$, tức ridge thường.
- DLinear: weight decay $\|W_t\|^2 + \|W_s\|^2$ trên hai nhánh bằng $\text{tr}(W_{\text{eff}} N^{-1} W_{\text{eff}}^\top)$ tại nghiệm, với $N = P^\top P + (I-P)^\top (I-P)$. Vậy Pen $= N^{-1}$. Vì $N \succeq \frac{1}{2} I$ nên $N^{-1} \preceq 2I$ (Phụ lục A).
- NLinear: phạt $L-1$ hệ số đầu của W_{eff}, không phạt lag cuối: Pen $= \text{diag}(1, \ldots, 1, 0)$. Với MSE, cách này bằng ridge trên chuỗi đã trừ giá trị cuối.

δ của Huber. Với mỗi (dataset, H, mô hình, tập train), lấy phần dư train R của nghiệm MSE $\lambda = 0$ của chính mô hình đó, rồi đặt

$$\hat{\sigma} = 1{,}4826 \cdot \text{median}\Big(|R - \text{median}(R)|\Big), \qquad \delta_{\text{MAD}} = 1{,}345\, \hat{\sigma}. \tag{6}$$

Trên grid gốc, δ_{MAD} nằm trong khoảng 0,37–0,73 (trung vị 0,54), tức nhỏ hơn $\delta = 1$ (mặc định của `HuberLoss` trong PyTorch) 1,4–2,7 lần. Trên các tập train đã chèn outlier, δ_{MAD} nằm trong khoảng 0,55–1,11. Một δ chung được dùng cho cả ô, dù $\hat{\sigma}$ theo từng bước h khác nhau nhiều. Một phương án gọn hơn là chuẩn hóa phần dư theo $\hat{\sigma}_h$ của từng bước rồi dùng một δ chung trên thang đã chuẩn hóa, tức $\delta_h = 1{,}345\, \hat{\sigma}_h$. Phương án này được thử như một phép kiểm độ nhạy trên hai ô (mục IV.2, hạn chế 5).

III.4. Bộ giải

- **MSE:** nghiệm dạng đóng. Với bias, cột **1** được nối vào X và hàng, cột tương ứng của hàm phạt bằng 0. NLinear dùng nghiệm có ràng buộc bằng nhân tử Lagrange, áp cho từng hàng h.
- **MAE, Huber:** IRLS trên GPU (PyTorch), khởi tạo từ nghiệm MSE. Mỗi vòng giải H hệ phương trình $p \times p$ ($p = L+1$) có trọng số. Lập ma trận hệ bằng float32 và mọi phần còn lại bằng float64, nên nghiệm có độ chính xác float64. Tiêu chí dừng: hàm mục tiêu giảm tương đối dưới `tol` sau một vòng. Khi quét λ, mỗi λ khởi tạo từ nghiệm của λ liền trước (warm start). Chi tiết và các phép kiểm ở Phụ lục B.

III.5. Chọn λ^*

Lưới λ của MSE gồm 0 và 141 giá trị cách đều theo log từ 10^{-2} đến 10^5. Lưới của MAE, Huber là $\{0, 1, 3, 10, \ldots, 10^4\}$, mở rộng thêm ở đầu mút nếu λ^* rơi vào đó. λ^* chỉ chọn trên val, không bao giờ trên test. MSE test được báo ở $\lambda^*_{\text{MSE}} = \arg\min_\lambda$ MSE val, và MAE test ở $\lambda^*_{\text{MAE}} = \arg\min_\lambda$ MAE val. Quy tắc này áp dụng như nhau cho mọi mô hình và mọi mục tiêu. Metric val không chứa số hạng phạt.

III.6. SGD

SGD dùng đúng siêu tham số của script chính thức LTSF-Linear. Đó là Adam theo mini-batch, batch 32 (ETTm1: 8), tối đa 10 epoch, dừng sớm theo MSE val với patience 3, và lr giảm một

nửa mỗi epoch (`lradj = type1`). lr ban đầu là 0,005 (ETTh1), 0,05 (ETTh2), 0,0001 (ETTm1); $k = 25$ cho DLinear. Ba mô hình dùng chung script. Mô hình sau huấn luyện được đọc ra dưới dạng W_{eff} và chấm bằng float64 trên đủ mọi cửa sổ val, test, cùng cách chấm với nghiệm tối ưu.

- **lr gốc:** 20 seed (2021–2040) cho mỗi (dataset, H, mô hình); riêng NLinear trên ETTh2 có 10 seed.
- **lr tinh chỉnh:** với mỗi ô, thử lr $\in \{0{,}5;\ 1;\ 2;\ 4\}\times$ lr gốc, mỗi mức 5 seed (2021–2025). Chọn mức có trung bình MSE val thấp nhất. Nếu chọn $\times 4$ thì thử thêm $\times 8$ một lần rồi chọn lại. Ô nào vẫn chọn mức ở đầu mút ($\times 0{,}5$ hoặc $\times 8$) thì thử tiếp mức kế tiếp theo hướng đó ($\times 0{,}25$ rồi $\times 0{,}125$; $\times 16$ rồi $\times 32$), cùng 5 seed. Mức mới được giữ nếu MSE val trung bình thấp hơn, tối đa hai mức mới, dừng ngay khi mức mới không tốt hơn. Lần chạy phân kỳ (MSE val không hữu hạn hoặc vượt 10 lần mức $\times 1$) tính là thất bại của mức đó. Sau đó chạy 15 seed mới (2026–2040) ở lr đã chọn. Mọi siêu tham số khác giữ như script gốc.

III.7. Outlier nhân tạo

Thí nghiệm outlier chạy trên ETTh1 với Linear và NLinear. Có hai cách chèn:

- **Chèn vào chuỗi:** chọn ngẫu nhiên đúng một tỷ lệ $\{1\%, 5\%, 10\%\}$ điểm (hàng, kênh) của chuỗi train đã chuẩn hóa, cộng ± 10 (dấu ngẫu nhiên), tức ± 10 độ lệch chuẩn của kênh. Scaler không tính lại. Cửa sổ train được cắt từ chuỗi đã chèn, nên một outlier xuất hiện ở nhiều cửa sổ, cả trong đầu vào x lẫn trong đích y. L hàng cuối của train không bị chèn, để val và test giữ nguyên từng byte.
- **Chèn chỉ vào đích:** chọn 1% hoặc 10% phần tử của Y train, cộng ± 10; X giữ nguyên. Đây là trường hợp "sạch" của lý thuyết hồi quy bền vững.

Seed vị trí là 2026; một số ô chạy thêm seed 2027, 2028. Thí nghiệm độ lớn (Linear, $H \in \{96, 720\}$) lặp lại với ± 3 và ± 5 độ lệch chuẩn, ở cùng vị trí outlier. Val và test luôn sạch, và λ^* chọn trên val sạch.

III.8. Thống kê và quy tắc đọc ba trường hợp

Với mỗi ô, đặt $\Delta = \text{SGD} - \text{dạng đóng}$, tính trên từng seed, cho cả MSE val và MSE test. Dạng đóng ở đây là nghiệm MSE tại λ^*. Khoảng tin cậy (CI) 95% của trung bình Δ tính theo phân phối t. Với mỗi tập, SGD *thắng* nếu CI nằm hẳn dưới 0, *thua* nếu nằm hẳn trên 0, và *hòa* nếu CI chứa 0. Ghép kết quả trên val và test cho sáu nhãn (Bảng 1); bảng hẹp ở Phụ lục C dùng mã T1–T6.

Bảng 1: Quy tắc đọc ba trường hợp: nhãn của một ô theo dấu của CI 95% của Δ = SGD − dạng đóng trên val và trên test.

mã	val	test	nhãn
T1	thắng	thắng	SGD tốt hơn thật
T2	thua	thua	dạng đóng tốt hơn thật
T3	hòa	thắng hoặc thua	khác biệt do val khác test
T4	thắng	hòa hoặc thua	SGD có dấu hiệu khớp val quá mức
T5	thua	hòa hoặc thắng	dạng đóng có dấu hiệu khớp val quá mức
T6	hòa	hòa	không phân biệt được

So sánh DLinear − Linear khi cùng huấn luyện bằng SGD dùng CI 95% Welch, vì hai mô hình chạy trên các seed độc lập. Mọi CI tính trên trung bình theo seed, không phải trên một lần chạy.

IV. Kết quả

IV.1. RQ1: khi nào DLinear và NLinear thu về Linear

Ba dự đoán. Từ biểu diễn W_{eff} ở mục III.2, Phụ lục A suy ra ba dự đoán:

(1) Khi $\lambda = 0$, DLinear trùng Linear: $[P, I - P]$ có hạng L nên tập các W_{eff} của DLinear đúng bằng tập của Linear.

(2) Khi $\lambda > 0$, DLinear tách khỏi Linear: weight decay của DLinear là ridge trong metric N^{-1} thay vì ridge đẳng hướng, nên mức tách phụ thuộc kernel k.

(3) NLinear tách khỏi Linear ở mọi λ, vì nó là Linear với ràng buộc tổng hàng bằng 1.

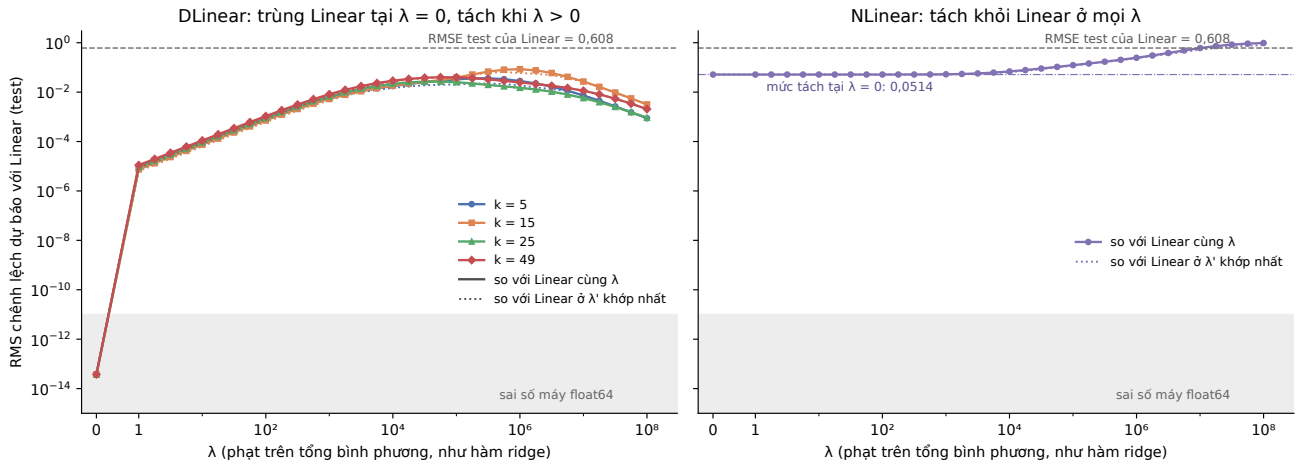
Bảng 2 tóm tắt phép kiểm trên ETTh1, $H = 96$. Nghiệm tối ưu được giải trong chính tham số hóa của module DLinear, NLinear của repo LTSF-Linear, rồi nạp vào module. Gradient qua autograd tại nghiệm gần bằng 0 so với lúc khởi tạo, nên nghiệm là cực tiểu toàn cục của hàm lồi. Cả ba dự đoán đều đúng.

Bảng 2: Ba dự đoán của RQ1, ETTh1, $L = 336$, $H = 96$, nghiệm tối ưu dạng đóng. ΔW: chênh của W_{eff} so với Linear cùng λ. RMS chênh dự báo: căn trung bình bình phương chênh lệch dự báo trên test, cùng đơn vị với RMSE.

	$\lambda = 0$	$\lambda > 0$
DLinear so với Linear	**Trùng** với cả 4 kernel k: $\operatorname{rank} Z = 336/672$; $\|\Delta W\|/\|W\| \le 5 \cdot 10^{-13}$; gradient qua module $\approx 6 \cdot 10^{-15}$ lần lúc khởi tạo.	**Tách**, mức tách tăng theo k. Tại $\lambda = 10^4$, $k = 5/15/25/49$: $\|\Delta W\|/\|W\| =$ 0,12/0,19/0,28/0,37; không λ' nào của Linear xóa được phần tách.
NLinear so với Linear	**Tách**: $\|\Delta W\|_F = 0{,}0694$; RMS chênh dự báo test 0,0514.	**Tách**, tăng theo λ: RMS chênh 0,069 ($\lambda = 10^4$) đến 0,973 ($\lambda = 10^8$).

- **DLinear, $\lambda = 0$.** Ma trận đặc trưng $Z = [XP^\top, X(I - P)^\top]$ có 672 cột nhưng hạng chỉ 336. Đó là gốc đại số của dự đoán (1): hai nhánh cộng lại đúng bằng x. W_{eff} của DLinear trùng Linear tới sai số máy ($\le 5 \cdot 10^{-13}$ tương đối) với cả bốn kernel $k \in \{5, 15, 25, 49\}$.

- **DLinear, $\lambda > 0$.** Tại $\lambda = 10^4$, RMS chênh dự báo với Linear cùng λ là 0,017 / 0,018 / 0,022 / 0,029 với $k = 5/15/25/49$. Để kiểm phần tách có phải chỉ do đổi thang λ hay không, chúng tôi tìm λ' của Linear khớp DLinear nhất. Phần tách còn lại vẫn bằng khoảng 91% (trung vị trên lưới λ) so với khi so cùng λ. Vậy không có λ' nào của Linear tái tạo được DLinear có weight decay (Hình 1, trái).
- **NLinear.** Tại $\lambda = 0$, $\|W_{\text{eff}}^{\text{NLinear}} - W_{\text{eff}}^{\text{Linear}}\|_F = 0{,}0694$ đúng bằng $\|r\|\,\|u\|/s$ của Phụ lục A. Tổng bình phương lỗi train tăng đúng $\|r\|^2/s = 17002{,}8$. RMS chênh dự báo test là 0,0514, và tăng theo λ (Hình 1, phải).



Hình 1: RMS chênh lệch dự báo trên test giữa DLinear (trái, bốn kernel k) hoặc NLinear (phải) và Linear, theo λ; ETTh1, $H = 96$, nghiệm tối ưu. Nét liền: so với Linear cùng λ; nét chấm: so với Linear ở λ' khớp nhất. Dải xám: sai số máy float64. Đường đứt: RMSE test của Linear (0,608).

Độ lớn thực tế trên toàn bộ ma trận. Hai loại tách có độ lớn rất khác nhau ở mức phạt mà val chọn (Bảng 4).

- **DLinear so với Linear: nhỏ.** Trên 12 cặp (dataset, H), MSE test của DLinear và Linear ở λ^* (mục tiêu MSE) chênh nhau không quá 0,0006. Trên mọi tổ hợp mục tiêu và metric (72 cặp), mức chênh không quá 0,0016.
- **NLinear so với Linear: phụ thuộc dataset.** NLinear − Linear trên MSE test (mục tiêu MSE, theo H từ nhỏ đến lớn về độ lớn) là −0,0007–−0,0371 ở ETTh1, −0,0292–−0,3480 ở ETTh2 và 0,0012–0,0030 ở ETTm1. Trên số liệu này, ràng buộc tổng hàng bằng 1 có lợi rõ trên ETTh2 (tăng theo H) và ở ETTh1 $H = 720$, nhỏ ở các ô ETTh1 còn lại, và hơi bất lợi trên ETTm1.

ETTh1, $H = 720$. Trong Bảng 2 của bài gốc, DLinear tốt hơn Linear rõ nhất ở ô này: 0,472 so với 0,624 (chênh −0,152). Tại nghiệm tối ưu, hai mô hình cho 0,4697 và 0,4701. Với SGD của repo (20 seed, lr gốc), Linear cho 0,5063 ± 0,0363 và DLinear cho 0,5096 ± 0,0396. Chênh DLinear − Linear là +0,003 với CI 95% [−0,021; 0,028], tức không phát hiện khác biệt. Số công

bố của Linear (0,624) thuộc đuôi trên của phân phối theo seed (mục IV.3). ETTh2, $H = 720$ cho cùng kết luận: chênh trong bài là $-0{,}093$, còn trung bình theo seed là $-0{,}010$ [$-0{,}044$; $0{,}025$].

DLinear so với Linear khi huấn luyện bằng SGD. Bảng 3 so DLinear − Linear trên MSE test khi cả hai được huấn luyện bằng SGD. Với lr gốc, DLinear tốt hơn có ý nghĩa (CI Welch nằm hẳn dưới 0, trên cả val lẫn test) ở 4/12 ô, cả bốn đều trên ETTm1, với chênh $-0{,}0032$–$-0{,}0047$. Ở các ô đó, chênh tương ứng của nghiệm dạng đóng nhỏ hơn hẳn (cột cuối). Khi tinh chỉnh lr cho cả hai mô hình (mục III.6), không còn ô nào có khác biệt ý nghĩa (0/12). Ở ETTm1, chênh còn $-0{,}0020$–$0{,}0004$ và mọi CI chứa 0. Với lr gốc trên đúng 15 seed mới, cả 4/4 ô ETTm1 vẫn có ý nghĩa trên test. Vì vậy việc mất ý nghĩa là do lr, không do bớt seed. Không ô nào có Linear tốt hơn DLinear có ý nghĩa.

Bảng 3: DLinear − Linear, MSE test, huấn luyện bằng SGD. Trung bình theo seed, CI 95% Welch; âm nghĩa là DLinear tốt hơn; **đậm**: DLinear tốt hơn có ý nghĩa trên test. Cột lr: mức đã chọn cho từng mô hình (bội của lr gốc). Cột cuối: cùng hiệu số với nghiệm dạng đóng MSE ở λ^*.

Dataset	H	lr gốc, 20 seed	lr tinh chỉnh, 15 seed	lr (Linear / DLinear)	dạng đóng
ETTh1	96	−0,0020 [−0,0075; 0,0036]	+0,0003 [−0,0040; 0,0046]	×4 / ×1	−0,0004
ETTh1	192	−0,0105 [−0,0227; 0,0017]	−0,0145 [−0,0307; 0,0016]	×8 / ×2	−0,0004
ETTh1	336	+0,0020 [−0,0150; 0,0190]	−0,0043 [−0,0224; 0,0138]	×1 / ×0,5	−0,0006
ETTh1	720	+0,0033 [−0,0210; 0,0276]	−0,0096 [−0,0238; 0,0046]	×0,5 / ×8	−0,0004
ETTh2	96	−0,0055 [−0,0148; 0,0037]	−0,0064 [−0,0182; 0,0054]	×1 / ×1	−0,0001
ETTh2	192	−0,0154 [−0,0383; 0,0075]	−0,0195 [−0,0459; 0,0069]	×4 / ×0,5	+0,0000
ETTh2	336	+0,0033 [−0,0122; 0,0187]	+0,0007 [−0,0170; 0,0184]	×1 / ×1	+0,0000
ETTh2	720	−0,0098 [−0,0444; 0,0249]	−0,0193 [−0,0700; 0,0314]	×0,5 / ×1	+0,0000
ETTm1	96	**−0,0040 [−0,0052; −0,0028]**	+0,0004 [−0,0015; 0,0024]	×32 / ×2	+0,0000
ETTm1	192	**−0,0032 [−0,0041; −0,0024]**	−0,0010 [−0,0028; 0,0008]	×8 / ×2	+0,0000
ETTm1	336	**−0,0038 [−0,0054; −0,0021]**	−0,0020 [−0,0073; 0,0033]	×8 / ×4	+0,0000
ETTm1	720	**−0,0047 [−0,0069; −0,0025]**	−0,0020 [−0,0058; 0,0017]	×2 / ×2	+0,0000

Trả lời RQ1

Tại nghiệm tối ưu, DLinear thu về đúng Linear khi không phạt, và chỉ tách khi có weight decay, qua metric N^{-1} phụ thuộc kernel. NLinear là Linear có ràng buộc tổng hàng nên tách ở mọi λ. Ở λ^* chọn trên val, khác biệt DLinear − Linear rất nhỏ trên test. Khác biệt NLinear − Linear thì phụ thuộc dữ liệu: lớn trên ETTh2, nhỏ trên ETTh1 (trừ $H = 720$) và ETTm1. Lợi thế của DLinear so với Linear trong các bảng công bố không xuất hiện ở nghiệm tối ưu. Với SGD, nó chỉ xuất hiện ở ETTm1 khi dùng lr gốc, và biến mất khi tinh chỉnh lr.

IV.2. RQ2: hàm mục tiêu và outlier

Bảng 4 cho sai số test tại nghiệm tối ưu của ba mục tiêu. Bản đủ, gồm $\lambda = 0$, λ^* và δ, là Bảng 9 ở Phụ lục C. MSE test được báo ở λ^*_{MSE}, MAE test ở λ^*_{MAE} (mục III.5), và Huber dùng δ_{MAD}.

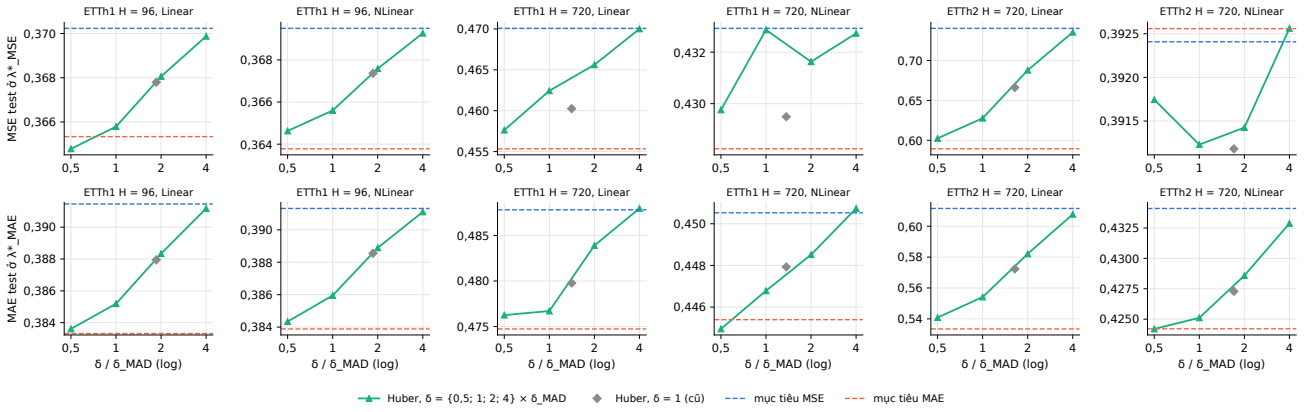
Bảng 4: Sai số test tại nghiệm tối ưu của ba mục tiêu huấn luyện (cột MSE, MAE, Huber trong mỗi nhóm). **Đậm**: thấp nhất giữa ba mục tiêu trong cùng (dataset, H, mô hình, metric).

			MSE test ở λ^*_{MSE}			MAE test ở λ^*_{MAE}		
Dataset	Mô hình	H	MSE	MAE	Huber	MSE	MAE	Huber
ETTh1	Linear	96	0,3702	**0,3653**	0,3658	0,3915	**0,3833**	0,3852
ETTh1	Linear	192	0,4040	0,4031	**0,4025**	0,4126	**0,4074**	0,4082
ETTh1	Linear	336	0,4324	0,4302	**0,4296**	0,4340	**0,4275**	0,4285
ETTh1	Linear	720	0,4701	**0,4553**	0,4624	0,4878	**0,4747**	0,4767
ETTh1	DLinear	96	0,3698	**0,3647**	0,3652	0,3914	**0,3832**	0,3851
ETTh1	DLinear	192	0,4036	**0,4014**	0,4017	0,4125	**0,4074**	0,4080
ETTh1	DLinear	336	0,4317	0,4296	**0,4290**	0,4340	**0,4272**	0,4285
ETTh1	DLinear	720	0,4697	**0,4549**	0,4620	0,4879	**0,4746**	0,4766
ETTh1	NLinear	96	0,3695	**0,3638**	0,3656	0,3913	**0,3839**	0,3860
ETTh1	NLinear	192	0,4027	0,4026	**0,4024**	0,4110	**0,4075**	0,4084
ETTh1	NLinear	336	**0,4261**	0,4290	0,4307	0,4260	**0,4237**	0,4246
ETTh1	NLinear	720	0,4329	**0,4282**	0,4329	0,4505	**0,4454**	0,4468
ETTh2	Linear	96	0,3009	**0,2779**	0,2818	0,3649	**0,3334**	0,3410
ETTh2	Linear	192	0,3966	**0,3531**	0,3600	0,4273	**0,3855**	0,3945
ETTh2	Linear	336	0,4853	**0,4106**	0,4220	0,4835	**0,4296**	0,4400
ETTh2	Linear	720	0,7404	**0,5893**	0,6277	0,6115	**0,5335**	0,5541
ETTh2	DLinear	96	0,3008	**0,2778**	0,2817	0,3649	**0,3333**	0,3410
ETTh2	DLinear	192	0,3966	**0,3531**	0,3600	0,4273	**0,3855**	0,3945
ETTh2	DLinear	336	0,4853	**0,4106**	0,4220	0,4835	**0,4296**	0,4400
ETTh2	DLinear	720	0,7403	**0,5892**	0,6276	0,6115	**0,5335**	0,5541
ETTh2	NLinear	96	**0,2717**	0,2764	0,2756	0,3342	0,3307	**0,3306**
ETTh2	NLinear	192	**0,3336**	0,3447	0,3427	0,3754	0,3756	**0,3744**
ETTh2	NLinear	336	**0,3581**	0,3760	0,3727	**0,3997**	0,4028	0,4008
ETTh2	NLinear	720	0,3924	0,3926	**0,3912**	0,4341	**0,4242**	0,4251
ETTm1	Linear	96	0,2992	**0,2929**	0,2953	0,3427	**0,3331**	0,3362
ETTm1	Linear	192	0,3340	**0,3322**	0,3327	0,3637	**0,3553**	0,3578
ETTm1	Linear	336	0,3683	**0,3658**	0,3661	0,3843	**0,3759**	0,3782
ETTm1	Linear	720	0,4232	0,4216	**0,4210**	0,4181	**0,4101**	0,4120
ETTm1	DLinear	96	0,2992	**0,2929**	0,2952	0,3427	**0,3331**	0,3362
ETTm1	DLinear	192	0,3339	**0,3319**	0,3326	0,3637	**0,3553**	0,3578
ETTm1	DLinear	336	0,3683	**0,3655**	0,3660	0,3843	**0,3759**	0,3782
ETTm1	DLinear	720	0,4232	0,4213	**0,4208**	0,4181	**0,4101**	0,4121
ETTm1	NLinear	96	0,3004	**0,2937**	0,2964	0,3426	**0,3337**	0,3367
ETTm1	NLinear	192	0,3356	**0,3335**	0,3345	0,3634	**0,3563**	0,3585
ETTm1	NLinear	336	0,3703	**0,3685**	0,3691	0,3834	**0,3770**	0,3790
ETTm1	NLinear	720	**0,4262**	0,4270	0,4264	0,4157	**0,4113**	0,4126

MAE so với MSE. Huấn luyện bằng MAE cho MSE test thấp hơn huấn luyện bằng MSE ở 30/36 ô. Với Linear và DLinear, điều này đúng ở cả 4 horizon của ETTh1, ETTh2 và ETTm1. Chênh lớn nhất ở ETTh2 (0,023–0,151), nhỏ ở ETTh1 (0,001–0,015) và ETTm1 (0,002–0,006). Với NLinear, MAE tốt hơn ở 3/4 horizon của ETTh1 và 3/4 của ETTm1, nhưng kém hơn ở cả 4 horizon của ETTh2 (chênh $-0{,}0178$–$-0{,}0002$). Theo MSE test, mục tiêu tốt nhất trong ô là MAE ở 24 ô, Huber ở 7 và MSE ở 5. Theo MAE test, các con số là 33 / 2 / 1. Trên ETTh2, khoảng một nửa lợi thế của MAE với Linear ở $H \geq 336$ đến từ các đoạn cảm biến bị kẹt (mục IV.4).

Vị trí của Huber. Huber đứng giữa MSE và MAE ở 28/36 ô theo MSE test và 34/36 theo MAE test. So với $\delta = 1$ cố định (mặc định của `HuberLoss` trong PyTorch), δ_{MAD} cho MSE test thấp hơn ở 27/36 ô và MAE test thấp hơn ở 34/36. Lợi lớn nhất ở ETTh2 Linear $H = 720$ (MSE test 0,6662 → 0,6277), nơi MAE vượt xa MSE.

Độ nhạy theo δ. Hình 2 quét $\delta \in \{0{,}5;\ 1;\ 2;\ 4\} \times \delta_{\text{MAD}}$ trên 6 ô. MAE test tăng đơn điệu theo δ ở 6/6 ô: δ nhỏ đưa Huber về MAE. Huber đứng hạng 2 ở 50/60 trường hợp (ô, metric, δ), kể cả $\delta = 1$. Giá trị tuyệt đối nhạy với δ ở ETTh2 Linear $H = 720$ (MSE test 0,602–0,735), gần hết khoảng giữa MAE và MSE. Ở ETTh1, biên độ chỉ 0,003–0,012.



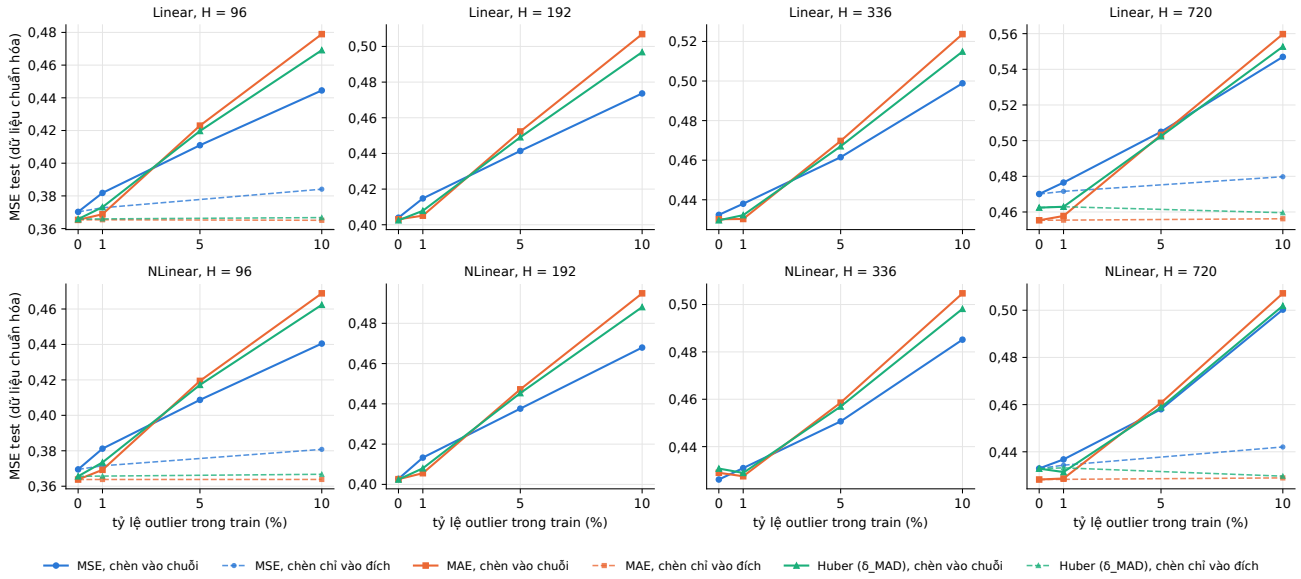
Hình 2: Độ nhạy của Huber theo δ. Trục hoành $\delta/\delta_{\text{MAD}}$ (log); hình thoi xám: $\delta = 1$ cố định. Đường đứt: mục tiêu MSE (xanh) và MAE (cam). Hàng trên: MSE test ở λ^*_{MSE}; hàng dưới: MAE test ở λ^*_{MAE}.

δ theo từng bước h. Một δ chung cho cả ô nằm trong vùng bậc hai với các bước gần và gần vùng tuyến tính với các bước xa, vì $\hat{\sigma}_h$ tăng theo h. Chúng tôi thử chuẩn hóa phần dư theo $\hat{\sigma}_h$ của từng bước rồi dùng một δ chung trên thang đã chuẩn hóa, tức $\delta_h = 1{,}345\,\hat{\sigma}_h$, trên hai ô: ETTh2 $H = 720$ Linear, nơi Huber nhạy với δ nhất, và ETTh1 $H = 96$ Linear. Ở ETTh2, δ_h trải từ 0,174 đến 0,801 quanh $\delta_{\text{MAD}} = 0{,}610$. MSE test đổi từ 0,6277 (δ_{MAD}) thành 0,6357 (δ_h); ở ETTh1, từ 0,3658 thành 0,3656. Huber vẫn đứng giữa MSE và MAE theo cả hai metric ở cả hai ô (Bảng 14, Phụ lục C). Vậy cách đặt δ theo bước không đổi vị trí của Huber ở hai ô đã thử.

Outlier chỉ ở đích. Khi cộng ± 10 độ lệch chuẩn vào 1% hoặc 10% phần tử đích của train ETTh1 (đầu vào giữ nguyên), MSE test của MAE và Huber đổi không quá 0,003. Trong khi đó,

MSE test của mục tiêu MSE tăng tới 0,014 (nét đứt trong Hình 3). Đây là hành vi mà lý thuyết hồi quy bền vững dự đoán.

Outlier trong chuỗi. Khi outlier nằm trong chuỗi, tức xuất hiện cả ở đầu vào, thứ hạng đổi theo tỷ lệ (Hình 3, nét liền; bảng đầy đủ ở Phụ lục C). Ở 1%, MAE tốt nhất theo MSE test ở 8/8 ô (Linear, NLinear × 4 horizon). Ở 5%, MSE tốt nhất ở 7/8, và ở 10% là 8/8. Mức suy giảm MSE test từ 0 đến 10% là 0,059–0,077 với MSE, 0,067–0,103 với Huber và 0,076–0,114 với MAE. Thứ tự MSE < Huber < MAE đúng ở 8/8 ô. Độ lệch theo vị trí outlier (Linear, $H = 96$, 10%, seed 2026–2028) là 0,012–0,015, cùng cỡ khác biệt giữa MSE và Huber.

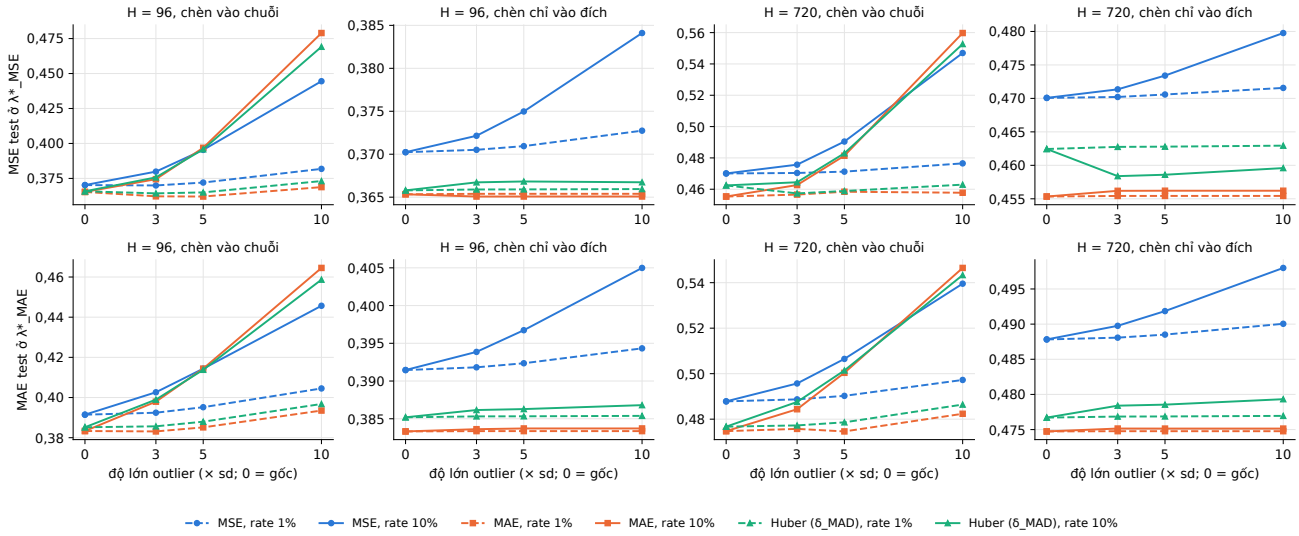


Hình 3: MSE test theo tỷ lệ outlier trong train, ETTh1, outlier ±10 độ lệch chuẩn, seed 2026; λ^* chọn theo MSE val sạch; Huber dùng δ_{MAD} của chính tập train đã chèn. Nét liền: chèn vào chuỗi (0, 1, 5, 10%); nét đứt: chèn chỉ vào đích (0, 1, 10%, chỉ $H = 96, 720$). Bản theo MAE test ở Phụ lục C.

Độ lớn outlier. Hình 4 lặp lại thí nghiệm với outlier nhỏ hơn (3σ, 5σ) ở cùng vị trí, cho Linear trên ETTh1 với một seed.

- Chèn vào chuỗi ở 10%, 3σ: MAE vẫn tốt nhất ở cả hai horizon. Ở $H = 96$, ba mục tiêu suy giảm gần bằng nhau (MSE +0,0096, MAE +0,0091, Huber +0,0099).
- Ở 10%, 5σ, $H = 96$: ba mục tiêu chênh không quá 0,0015, nhỏ hơn độ lệch theo seed. Ở $H = 720$, MAE vẫn tốt hơn MSE (0,4814 so với 0,4904).
- Ở 10%, 10σ: MSE tốt nhất ở cả hai horizon.
- Chèn chỉ vào đích: MSE suy giảm gần tỷ lệ với độ lớn ($H = 96$, 10%: +0,0019 / +0,0047 / +0,0139 ở 3σ / 5σ / 10σ), còn MAE và Huber gần như không đổi.

Như vậy, MAE và Huber chỉ mất lợi thế khi outlier vừa nhiều (10%) vừa lớn (từ khoảng 5σ) và nằm cả trong đầu vào.



Hình 4: Sai số test theo độ lớn outlier, Linear, ETTh1, seed 2026, cùng vị trí outlier ở mọi độ lớn. Hàng trên: MSE test ở λ^*_{MSE}; hàng dưới: MAE test ở λ^*_{MAE}. Trục hoành: độ lớn (bội của độ lệch chuẩn; 0 là dữ liệu gốc). Nét đứt: tỷ lệ 1%; nét liền: 10%.

Trả lời RQ2

Trên dữ liệu gốc, huấn luyện bằng MAE cho sai số test thấp hơn MSE ở phần lớn ô, kể cả khi đo bằng MSE. Lợi thế lớn nhất ở ETTh2, nơi một phần lợi thế đến từ các đoạn cảm biến bị kẹt; ngoại lệ là NLinear trên ETTh2. Huber với δ theo thang phần dư đứng giữa MSE và MAE ở phần lớn ô, và vị trí này ít nhạy với δ. MAE và Huber bền vững với outlier chỉ nằm ở đích. Khi outlier nằm trong chuỗi, chúng vẫn tốt nhất ở tỷ lệ thấp hoặc độ lớn nhỏ, nhưng suy giảm nhanh hơn MSE khi outlier vừa nhiều vừa lớn.

IV.3. RQ3: SGD so với nghiệm tối ưu

Số công bố. Bảng 5 so SGD của repo (lr gốc, 20 seed) với số công bố. Số công bố nằm trong khoảng từ seed tốt nhất đến seed kém nhất ở 28/36 ô. Ở 8/36 ô còn lại, chúng tôi không đạt được số công bố với 20 seed: số công bố thấp hơn mọi seed; 5 trong số đó là DLinear, không ô nào là Linear. Kết quả vẫn vậy khi chạy chính code gốc của LTSF-Linear ở cả 8 ô này, mỗi ô 5 seed (môi trường: PyTorch 2.14.0, CUDA 13.0, GPU RTX 5060 Ti, Windows 11; xem hạn chế 8). Hình 5 cho thấy toàn bộ phân phối theo seed cạnh nghiệm dạng đóng và số công bố.

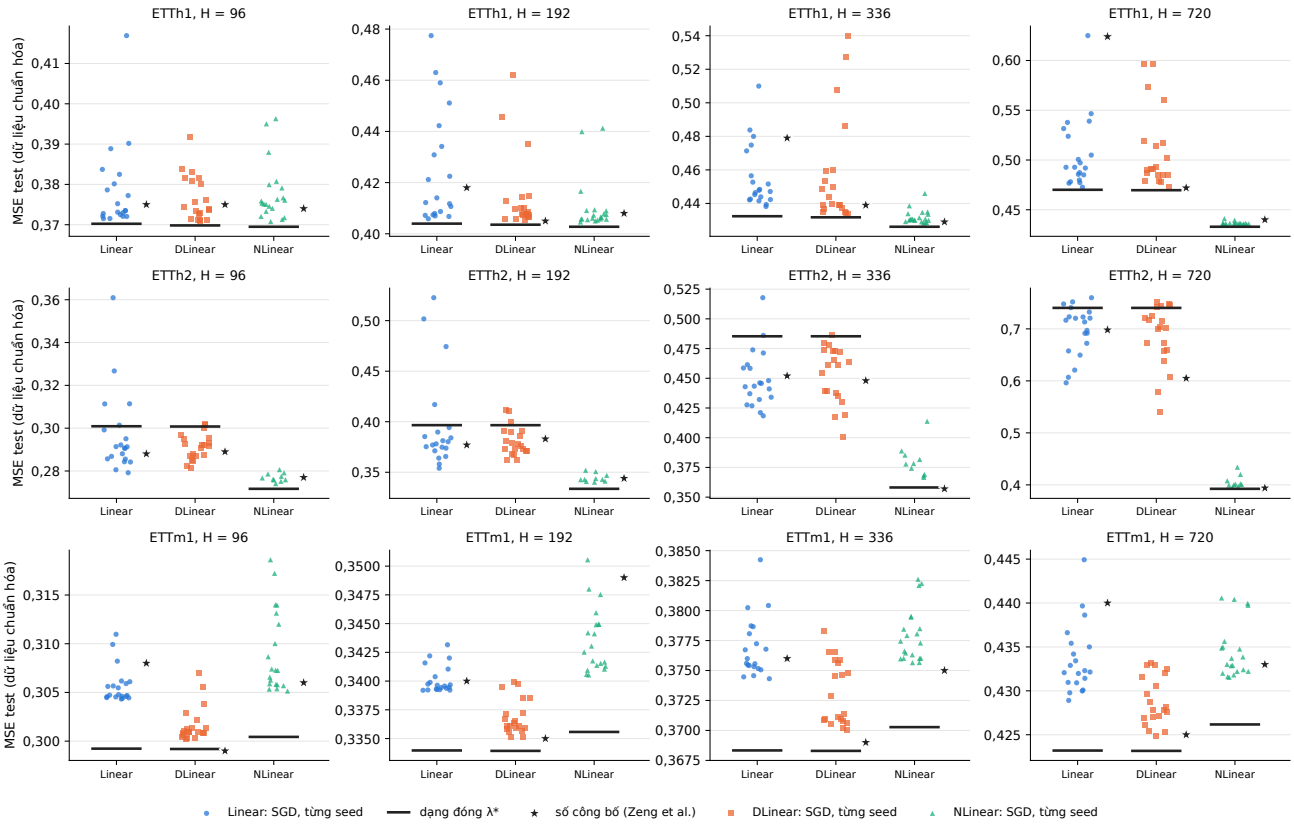
Bảng 5: MSE test của SGD (lr gốc; trung bình ± độ lệch chuẩn theo seed; 20 seed, số khác ghi trong ngoặc) và số công bố của LTSF-Linear. †**Đậm**: số công bố nằm ngoài khoảng [min, max] của các seed.

		Linear		DLinear		NLinear	
Dataset	H	SGD: TB ± sd	công bố	SGD: TB ± sd	công bố	SGD: TB ± sd	công bố
ETTh1	96	0,3786 ± 0,0107	0,375	0,3766 ± 0,0057	0,375	0,3779 ± 0,0072	0,374
ETTh1	192	0,4250 ± 0,0222	0,418	0,4146 ± 0,0152	**0,405**†	0,4105 ± 0,0106	0,408
ETTh1	336	0,4553 ± 0,0189	0,479	0,4573 ± 0,0322	0,439	0,4320 ± 0,0042	0,429
ETTh1	720	0,5063 ± 0,0363	0,624	0,5096 ± 0,0396	**0,472**†	0,4363 ± 0,0014	0,440
ETTh2	96	0,2968 ± 0,0191	0,288	0,2913 ± 0,0060	0,289	0,2770 ± 0,0020 (10)	0,277
ETTh2	192	0,3961 ± 0,0472	0,377	0,3807 ± 0,0145	0,383	0,3444 ± 0,0041 (10)	0,344
ETTh2	336	0,4496 ± 0,0241	0,452	0,4529 ± 0,0242	0,448	0,3804 ± 0,0139 (10)	**0,357**†
ETTh2	720	0,6967 ± 0,0484	0,698	0,6869 ± 0,0592	0,605	0,4058 ± 0,0122 (10)	**0,394**†
ETTm1	96	0,3057 ± 0,0019	0,308	0,3017 ± 0,0018	**0,299**†	0,3091 ± 0,0042	0,306
ETTm1	192	0,3401 ± 0,0012	0,340	0,3369 ± 0,0015	**0,335**†	0,3436 ± 0,0028	0,349
ETTm1	336	0,3769 ± 0,0025	0,376	0,3731 ± 0,0027	**0,369**†	0,3779 ± 0,0022	**0,375**†
ETTm1	720	0,4336 ± 0,0039	0,440	0,4289 ± 0,0028	0,425	0,4346 ± 0,0031	0,433

`drop_last` ở test loader của code gốc. Trong lịch sử repo LTSF-Linear, test loader dùng `drop_last=True` từ commit đầu tiên (`f7cbf46`, 27/05/2022) đến commit `6fe4c28` (15/03/2023), commit đổi thành `False`. README của repo ghi bài được nhận ở AAAI 2023 vào ngày 23/11/2022 (commit `571f26e`), tức trước khi đổi. Với `drop_last=True`, các cửa sổ test của batch cuối chưa đủ cỡ bị bỏ khỏi phép tính MSE test; đây là một lỗi đã biết của dòng codebase LTSF. Chúng tôi chạy lại code gốc ở 8 ô trên, cộng ETTh2 $H = 720$ DLinear để đối chứng, với cả hai giá trị của `drop_last` (Bảng 6; thay đổi duy nhất trong code gốc là tham số chọn `drop_last`). Số cửa sổ bị bỏ là 1–17 trên mỗi tập test, tức không quá 0,79%. Với `drop_last=True`, số công bố nằm trong khoảng [min; max] của 5 seed ở 1/8 ô (`drop_last=False`: 0/8). Huấn luyện của hai chế độ trùng nhau; chỉ phép chấm test khác. Mức chênh do `drop_last` (cùng seed, `True` − `False`) có độ lớn không quá $5 \cdot 10^{-3}$. Nó chỉ đáng kể ở các ô theo giờ (batch 32, số cửa sổ bị bỏ lớn nhất) và gần như bằng 0 trên ETTm1 (batch 8, một cửa sổ bị bỏ). Vì vậy `drop_last` không đủ giải thích khoảng chênh giữa số công bố và các lần chạy của chúng tôi ở phần lớn ô.

Bảng 6: Code gốc LTSF-Linear với `drop_last` của test loader bật và tắt, MSE test do code gốc in ra, 5 seed (2021–2025), siêu tham số của script gốc. **Đậm**: số công bố nằm trong [min; max] của các seed khi `drop_last=True`. *Ô đối chứng (số công bố nằm trong phân phối theo seed của repo).

		code gốc, 5 seed: TB [min; max]		
Ô	công bố	`drop_last=True`	`drop_last=False`	cửa sổ bỏ / tổng
ETTh1, 192, DLinear	0,405	0,4201 [0,4070; 0,4434]	0,4202 [0,4070; 0,4435]	1 / 2689
ETTh1, 720, DLinear	0,472	0,5091 [0,4909; 0,5384]	0,5101 [0,4919; 0,5393]	17 / 2161
ETTm1, 96, DLinear	0,299	0,3019 [0,3008; 0,3031]	0,3018 [0,3008; 0,3031]	1 / 11425
ETTm1, 192, DLinear	0,335	0,3376 [0,3356; 0,3419]	0,3376 [0,3356; 0,3419]	1 / 11329
ETTm1, 336, DLinear	0,369	0,3723 [0,3695; 0,3761]	0,3723 [0,3695; 0,3761]	1 / 11185
ETTh2, 336, NLinear	**0,357**	0,3618 [0,3568; 0,3647]	0,3670 [0,3621; 0,3698]	17 / 2545
ETTh2, 720, NLinear	0,394	0,4064 [0,3959; 0,4313]	0,4087 [0,3980; 0,4340]	17 / 2161
ETTm1, 336, NLinear	0,375	0,3787 [0,3754; 0,3866]	0,3787 [0,3754; 0,3866]	1 / 11185
ETTh2, 720, DLinear*	**0,605**	0,6645 [0,5731; 0,7318]	0,6655 [0,5746; 0,7328]	17 / 2161



Hình 5: MSE test của SGD theo seed (lr gốc; mỗi điểm một seed), so với nghiệm dạng đóng MSE ở λ^* (vạch đen) và số công bố (dấu sao). Mỗi ô một (dataset, H), thang trục tung riêng.

Khoảng cách SGD – nghiệm dạng đóng. Bảng 7 đếm nhãn theo quy tắc ở Bảng 1; số liệu từng ô ở Bảng 10 (Phụ lục C).

- **lr gốc:** trên ETTh1 và ETTm1, SGD kém nghiệm dạng đóng trên test ở 12/12 và 12/12 ô, với Δ test lần lượt +0,0034–+0,0400 và +0,0025–+0,0104. Trên ETTh1, SGD thường đạt val thấp hơn nhưng test cao hơn. Nhãn "SGD tốt hơn thật" chỉ có trên ETTh2, ở 6 ô, đều với Linear hoặc DLinear.
- **lr tinh chỉnh:** lr được chọn trải trên các mức (Bảng 11; ×0,125: 1 ô; ×0,25: 1; ×0,5: 6; ×1: 7; ×2: 7; ×4: 7; ×8: 5; ×16: 1; ×32: 1). Với lưới ×0,5 đến ×8, 15/36 ô chọn mức ở đầu mút. Mở rộng lưới ở các ô này theo cùng một quy tắc (mục III.6) làm đổi lr ở 4 ô; 2 ô vẫn chọn mức xa nhất sau hai mức mới (ETTm1 Linear $H = 96$ ở ×32; ETTh2 NLinear $H = 720$ ở ×0,125). Lựa chọn cũng nhiễu: ở 31/36 ô, mức được chọn hơn mức thứ hai chưa tới một sai số chuẩn (hạn chế 6).
- **Kết quả sau tinh chỉnh:** SGD vẫn kém nghiệm dạng đóng trên test ở 28/36 ô theo trung bình, 27/36 ô có ý nghĩa. Trên ETTh1 và ETTm1, con số là 23/24 ô có ý nghĩa, với Δ test +0,0020–+0,0290. Nhãn đổi ở 16 ô, trong đó 14 ô do lr (phần còn lại do bớt seed). "Dạng đóng tốt hơn thật" giảm từ 10 xuống 2 ô, chủ yếu chuyển thành "SGD có dấu hiệu khớp

val quá mức": tinh chỉnh lr giúp SGD trên val nhưng không giúp trên test. "SGD tốt hơn thật" còn 5 ô, vẫn chỉ trên ETTh2 với Linear hoặc DLinear.

Bảng 7: Số ô (trên 36) theo nhãn của quy tắc ba trường hợp, Δ = SGD − dạng đóng MSE ở λ^*. Cột giữa: lr gốc trên đúng 15 seed mới (2026–2040), để tách phần thay đổi do lr khỏi phần do bớt seed.

Nhãn	lr gốc, 20 seed	lr gốc, 15 seed mới	lr tinh chỉnh, 15 seed mới
T1: SGD tốt hơn thật	6	6	5
T2: dạng đóng tốt hơn thật	10	10	2
T3: val khác test	7	7	8
T4: SGD khớp val quá mức	12	11	17
T5: dạng đóng khớp val quá mức	0	0	0
T6: không phân biệt được	1	2	4
Tổng	36	36	36

Các cơ chế đã loại trừ trên ETTh2. Hiện tượng SGD tốt hơn nghiệm tối ưu trên cả val và test chỉ xuất hiện ở ETTh2, với Linear và DLinear. Chúng tôi đã kiểm và không thấy ủng hộ cho các giải thích sau:

- SGD ngầm co trọng số về một điểm khác 0. Tổng hàng của W_{eff} do SGD học không gần 1 hơn một cách nhất quán. Ridge co về dự báo trung bình hay dự báo lặp giá trị cuối gần như không đổi MSE test.
- Các đoạn cảm biến bị kẹt. Bỏ các cửa sổ hằng khỏi train giúp cả SGD lẫn nghiệm dạng đóng, và khoảng cách vẫn âm ở phần lớn ô (mục IV.4).
- Dừng sớm của gradient descent. Trên Linear ETTh2 $H = 720$, gradient descent toàn batch từ 0 hoặc từ khởi tạo của LTSF-Linear cho sai số val và test gần như trùng ridge ở λ^*, đúng như lý thuyết [8]. Adam toàn batch hòa trên val nhưng thắng trên test.
- Chính quy hóa L2 mạnh hơn. Trên đủ lưới 142 giá trị λ của ridge (Linear và DLinear, 4 horizon), kể cả λ cho MSE test thấp nhất, tức chọn λ bằng chính tập test (mức tham chiếu không hợp lệ để chọn mô hình), ridge vẫn kém SGD trung bình ở 8/8 ô với lr gốc và 8/8 ô với lr tinh chỉnh (Bảng 12, Phụ lục C). Không giá trị λ nào của ridge đạt mức của SGD trên ETTh2, nên lợi thế của SGD không phải một dạng chính quy hóa L2 mạnh hơn.

Kết quả không khớp mẫu nào đã đặt trước, nên chúng tôi không xác định được cơ chế (hạn chế 7).

Trả lời RQ3

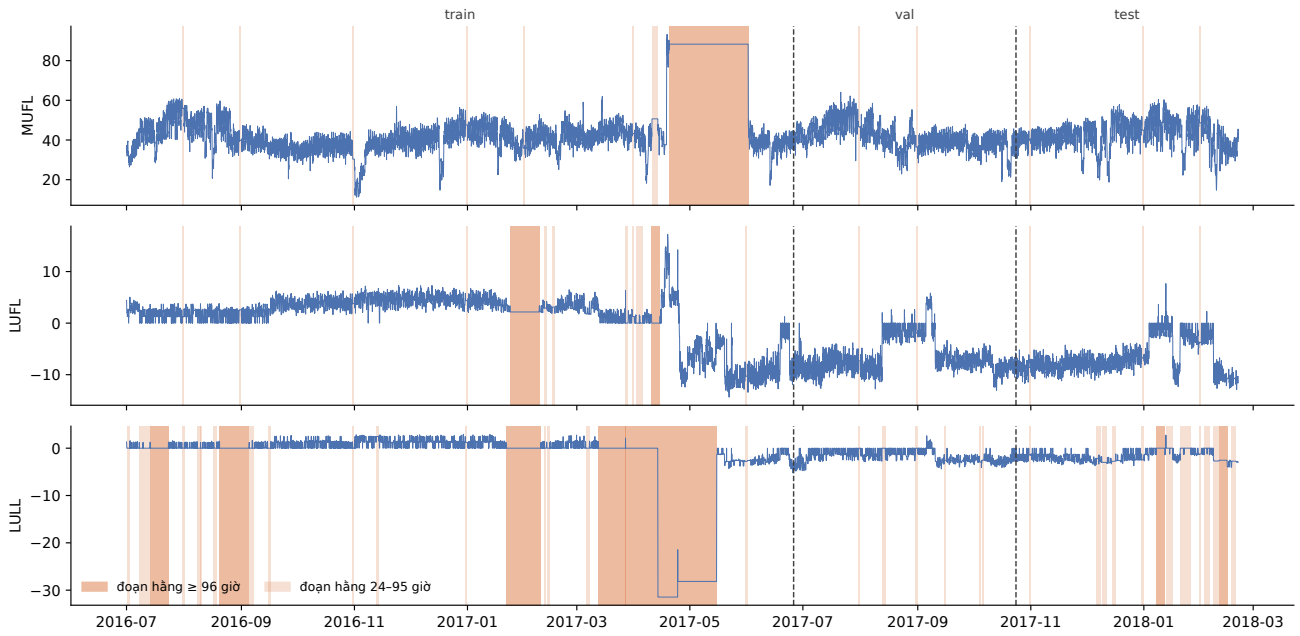
Với siêu tham số gốc, SGD kém nghiệm tối ưu trên test ở mọi ô của ETTh1 và ETTm1. Khoảng cách lớn hơn ở ETTh1 (+0,0034–+0,0400) so với ETTm1 (+0,0025–+0,0104); theo bảng đầy đủ ở Phụ lục C, với Linear và DLinear trên ETTh1 nó tăng theo horizon, còn với NLinear thì không. Tinh chỉnh learning rate trên val không đóng được khoảng cách này trên test: SGD vẫn kém ở 27/36 ô (có ý nghĩa). Ngoại lệ duy nhất là ETTh2 với Linear và DLinear: ở đó SGD tốt hơn nghiệm tối ưu trên cả val và test, chưa rõ cơ chế. Số công bố (một lần chạy) nằm trong khoảng giữa seed tốt nhất và kém nhất ở 28/36 ô. Các chênh lệch lớn giữa DLinear và Linear ở $H = 720$ trong bảng công bố không xuất hiện khi lấy trung bình theo seed.

IV.4. ETTh2 và các đoạn cảm biến bị kẹt

ETTh2 chứa các đoạn mà một kênh giữ nguyên một giá trị trong thời gian dài, nhiều khả năng do cảm biến bị kẹt.

Cách phát hiện. Một cửa sổ của một kênh (sau chuẩn hóa) được coi là *hằng* nếu $\max - \min$ của đầu vào x hoặc của đích y nhỏ hơn 10^{-12}. Đầu vào dài $L = 336$ nên chỉ đoạn hằng dài ít nhất 336 giờ mới tạo được đầu vào hằng; đích hằng cần đoạn dài ít nhất H giờ. Theo tiêu chí này, 2,5–6,3% số cửa sổ train (tùy H) là hằng, và mọi cửa sổ hằng của train thuộc ba kênh tải MUFL, LUFL, LULL.

Vị trí. Trên chuỗi gốc (trước khi cắt cửa sổ), có 163 đoạn mà một kênh lặp lại cùng một giá trị ít nhất 24 giờ liên tiếp. 63 đoạn trong số đó dài đúng 24 giờ và rơi vào ngày 31 của tháng, ở cả bảy kênh; các đoạn này quá ngắn để tạo cửa sổ hằng. 19 đoạn dài ít nhất 96 giờ (Bảng 13, Phụ lục C): 10 đoạn ở train (MUFL, LUFL, LULL; dài nhất 1025 giờ, MUFL từ 19/04 đến 01/06/2017), 1 ở val và 8 ở test (HULL, LULL). Hình 6 vẽ ba kênh tải theo thời gian cùng các đoạn hằng và ranh giới train/val/test.



Hình 6: Ba kênh tải của ETTh2 (giá trị gốc) theo thời gian. Vùng tô: đoạn kênh giữ nguyên một giá trị ít nhất 24 giờ (đậm: ít nhất 96 giờ, đủ dài để tạo cửa sổ đích hằng). Nét đứt: ranh giới train/val/test.

Kết quả có lọc và không lọc. Mọi kết quả chính ở trên dùng dữ liệu gốc. Phần này là phân tích độ nhạy: bỏ các cửa sổ hằng khỏi train, giữ nguyên val và test. Bảng 8 đặt kết quả gốc và đã lọc cạnh nhau.

Bảng 8: ETTh2, gốc / đã lọc (bỏ cửa sổ hằng khỏi train; val, test giữ nguyên), MSE test. SGD: lr gốc, 20 seed (NLinear: 10 seed, chưa chạy trên train đã lọc, "–"). Lợi thế của MAE: MSE test của mục tiêu MSE trừ MSE test của mục tiêu MAE, cùng $\lambda = 0$ (dương: MAE tốt hơn). ‡DLinear ở $\lambda = 0$ trùng Linear với mọi mục tiêu.

		MSE test, gốc / đã lọc		$\lambda = 0$, gốc / đã lọc	
Mô hình	H	dạng đóng, λ^*	SGD, TB theo seed	MSE test của MAE	lợi thế của MAE
Linear	96	0,3009 / 0,3146	0,2968 / 0,3160	0,2789 / 0,2874	+0,0230 / +0,0278
Linear	192	0,3966 / 0,3954	0,3961 / 0,3981	0,3541 / 0,3668	+0,0431 / +0,0290
Linear	336	0,4853 / 0,4553	0,4496 / 0,4478	0,4116 / 0,4209	+0,0742 / +0,0348
Linear	720	0,7404 / 0,6462	0,6967 / 0,6015	0,5898 / 0,5564	+0,1509 / +0,0900
DLinear	96	0,3008 / 0,3145	0,2913 / 0,2989	0,2789 / 0,2874‡	+0,0230 / +0,0278‡
DLinear	192	0,3966 / 0,3954	0,3807 / 0,3814	0,3541 / 0,3668‡	+0,0431 / +0,0290‡
DLinear	336	0,4853 / 0,4553	0,4529 / 0,4313	0,4116 / 0,4209‡	+0,0742 / +0,0348‡
DLinear	720	0,7403 / 0,6461	0,6869 / 0,6109	0,5898 / 0,5564‡	+0,1509 / +0,0900‡
NLinear	96	0,2717 / 0,2715	0,2770 / –	0,2781 / 0,2755	−0,0055 / −0,0031
NLinear	192	0,3336 / 0,3317	0,3444 / –	0,3464 / 0,3424	−0,0121 / −0,0100
NLinear	336	0,3581 / 0,3556	0,3804 / –	0,3779 / 0,3731	−0,0191 / −0,0168
NLinear	720	0,3924 / 0,3908	0,4058 / –	0,3945 / 0,3921	−0,0015 / −0,0006

- Ở $H = 720$, việc lọc làm MSE test của Linear và DLinear giảm 0,076–0,095, với cả nghiệm dạng đóng (Linear: 0,740 → 0,646) lẫn SGD (Linear, trung bình 20 seed: 0,697 → 0,601).
- Ở $H = 96$, việc lọc làm MSE test tăng 0,01–0,02.
- Ở 3/4 ô có $H \geq 336$ (Linear, DLinear), SGD cũng cải thiện khi lọc và vẫn tốt hơn nghiệm dạng đóng. Đoạn hằng vì vậy không giải thích được phần lớn việc SGD tốt hơn trên ETTh2.
- Đoạn hằng giải thích được khoảng một nửa lợi thế của MAE với Linear ở $H \geq 336$: sau khi lọc còn lại 47% ($H = 336$) và 60% ($H = 720$) lợi thế.
- NLinear gần như không bị ảnh hưởng bởi việc lọc.

V. Thảo luận

Kiến trúc so với huấn luyện. Câu hỏi ban đầu là ưu thế của DLinear, NLinear đến từ kiến trúc hay từ cách huấn luyện. Ở nghiệm tối ưu, câu trả lời khác nhau giữa hai biến thể. Với DLinear, phần kiến trúc gần như không còn: DLinear không phạt có cùng tập ánh xạ như Linear, và ở λ^* hai mô hình chênh không quá 0,0016 trên test (mục IV.1). Các khác biệt lớn giữa DLinear và Linear trong bảng công bố, ví dụ −0,152 ở ETTh1 $H = 720$, vì vậy phải đến từ quá trình huấn luyện. Với NLinear, ràng buộc tổng hàng là một khác biệt kiến trúc thật, và nó có lợi rõ trên ETTh2 ngay cả ở nghiệm tối ưu. Khi huấn luyện bằng SGD với lr gốc, DLinear tốt hơn Linear có ý nghĩa ở ETTm1, và lợi thế này biến mất khi lr được tinh chỉnh riêng cho từng mô hình. Trên ETTm1, Linear chọn lr từ ×8 trở lên ở 3/4 horizon, còn DLinear chọn không quá ×2 ở 3/4. Điều này phù hợp với *giả thuyết* rằng DLinear có learning rate hiệu dụng lớn hơn Linear ở cùng lr danh nghĩa. Chúng tôi chưa kiểm giả thuyết này.

Outlier ở đích so với outlier ở đầu vào. Lý thuyết hồi quy bền vững bảo vệ khỏi outlier trong biến đích. Kết quả khi chèn chỉ vào đích khớp với lý thuyết: MAE và Huber gần như không đổi, còn MSE suy giảm theo độ lớn outlier. Khi outlier nằm trong chuỗi, cùng một điểm bất

thường xuất hiện ở cả đầu vào của nhiều cửa sổ. Hàm mất mát chỉ hạ trọng số các phần dư lớn, nên không chặn được ảnh hưởng của các hàng đầu vào bất thường. Ở tỷ lệ cao và độ lớn lớn, MAE và Huber suy giảm nhanh hơn MSE.

Giả thuyết nhiễu đầu vào (chưa kiểm). Ở tỷ lệ 5% và 10% (chèn vào chuỗi), val chọn $\lambda^* = 0$ ở mọi đường λ: 64/64 trường hợp (đường, metric) với MSE và MAE, và cả 36 trường hợp với Huber. Một cách giải thích khả dĩ: outlier trong đầu vào tác động như nhiễu cộng vào x. Với hàm mất mát bình phương, huấn luyện với nhiễu đầu vào tương đương, ở bậc thấp nhất, với chính quy hóa Tikhonov [9]. Nếu vậy, dữ liệu có outlier đã tự mang một lượng ridge ngầm, nên không cần phạt tường minh nữa, và MSE được "chính quy hóa sẵn" theo cách mà MAE không có. Đây là *giả thuyết*. Chúng tôi chưa thiết kế phép kiểm nào cho nó, chẳng hạn so nghiệm MSE trên dữ liệu có outlier trong x với ridge trên dữ liệu sạch ở một λ tương ứng.

Nhiễu theo seed trong các bảng công bố. Bảng của bài gốc báo một lần chạy cho mỗi cấu hình. Ở một số ô, độ lệch chuẩn theo seed của SGD cùng cỡ với chênh lệch giữa các mô hình mà bài báo cáo (Bảng 5). Ví dụ ở ETTh2, $H = 720$, độ lệch chuẩn là 0,0484 (Linear) và 0,0592 (DLinear), trong khi chênh trong bài là $-0{,}093$. So sánh giữa các mô hình tuyến tính vì vậy cần nhiều seed và khoảng tin cậy. Hoặc, như ở đây, so tại nghiệm tối ưu, nơi không còn nhiễu theo seed.

VI. Hạn chế và hướng phát triển

Báo cáo có 11 hạn chế. Hạn chế 7 và 8 rút ra khi phân tích ETTh2 và số công bố; các hạn chế còn lại đã biết từ khi thiết kế thí nghiệm.

1. **Dữ liệu.** Chỉ ba dataset ETT, cùng 7 kênh, và chỉ là hai nguồn độc lập: ETTh1 và ETTm1 đo cùng một máy biến áp, chỉ khác tần suất lấy mẫu; ETTh2 đo máy thứ hai. Một kết quả lặp lại trên cả ETTh1 lẫn ETTm1 vì vậy không phải hai lần xác nhận độc lập. Phép kiểm qua module LTSF-Linear và phép quét kernel của RQ1 chỉ chạy ở ETTh1, $H = 96$. Dẫn xuất đại số đúng cho mọi ô, nhưng độ lớn của phần tách theo k chưa đo ở ô khác. *Hướng phát triển:* thêm các dataset khác của LTSF-Linear (Electricity, Traffic, Weather) và quét kernel trên toàn ma trận.

2. **Mô hình.** Chỉ mô hình tuyến tính, dùng chung trọng số cho mọi kênh, với $L = 336$ cố định và $k = 25$ trong grid. Kết luận không áp dụng trực tiếp cho biến thể `individual = True` hay cho mô hình phi tuyến.

3. **Val và test của ETT thuộc hai chế độ khác nhau.** Trên ETTh1, MSE val cao hơn hẳn MSE test. Mọi lựa chọn dựa trên val (λ^*, lr, epoch dừng) chịu giới hạn này: quy tắc ba trường hợp gán nhãn "khác biệt do val khác test" cho 7/36 ô với lr gốc và 8/36 ô với lr tinh chỉnh (Bảng 7). Ví dụ khác: trên ETTh1 và ETTm1, co ridge về dự báo lặp giá trị cuối thay vì về 0 làm MSE val thấp hơn nhưng MSE test cao hơn ở gần như mọi tổ hợp đã thử. *Hướng phát triển:* chọn siêu tham số bằng kiểm định chéo theo thời gian (nhiều đoạn val) thay vì một đoạn val duy nhất.

4. **Outlier nhân tạo.** Chỉ một dạng outlier: cộng $\pm k$ độ lệch chuẩn vào từng điểm ở vị trí ngẫu nhiên, chỉ trên ETTh1, chỉ với Linear và NLinear. Thí nghiệm độ lớn (3σ, 5σ) chỉ có Linear, $H \in \{96, 720\}$ và một seed. Outlier thật (như các đoạn cảm biến bị kẹt của ETTh2) có cấu trúc khác.

5. **Một δ chung cho cả ô.** $\hat{\sigma}$ của phần dư theo từng bước h chênh nhau nhiều trong một ô, nên một δ chung nằm trong vùng bậc hai với các bước gần và gần vùng tuyến tính với các bước xa. Chuẩn hóa phần dư theo $\hat{\sigma}_h$ rồi dùng một δ chung (tức $\delta_h = 1{,}345\,\hat{\sigma}_h$) chỉ được thử ở 2 ô (ETTh2 $H = 720$ và ETTh1 $H = 96$, Linear). Ở cả hai ô, Huber vẫn đứng giữa MSE và MAE (Bảng 14), nhưng kết luận này chưa được kiểm trên toàn ma trận.

6. **Lưới learning rate.** Lưới lr ban đầu là $\times 0{,}5$ đến $\times 8$ lr gốc; 15/36 ô chọn mức ở đầu mút. Ở các ô này, lưới được mở rộng thêm tối đa hai mức theo cùng một quy tắc ($\times 0{,}25$, $\times 0{,}125$ hoặc $\times 16$, $\times 32$), và lr chọn đổi ở 4 ô. 2 ô vẫn chọn mức xa nhất đã thử (ETTm1 Linear $H = 96$ ở $\times 32$; ETTh2 NLinear $H = 720$ ở $\times 0{,}125$), nên lr tối ưu trên val của chúng có thể còn nằm ngoài khoảng đã thử. Lựa chọn lr cũng nhiễu (31/36 ô có khoảng cách tới mức thứ hai dưới một sai số chuẩn). Chỉ lr được tinh chỉnh; batch, số epoch, patience giữ như script gốc.

7. **Cơ chế trên ETTh2 chưa rõ.** SGD tốt hơn nghiệm tối ưu trên cả val và test ở ETTh2 với Linear và DLinear. Các giải thích đã kiểm (co về trọng số khác 0, đoạn cảm biến bị kẹt, dừng sớm của gradient descent toàn batch) đều không khớp. Giả thuyết nhiễu đầu vào ở mục V cũng chưa được kiểm.

8. **Pipeline SGD và số công bố.** SGD của repo khác code gốc của LTSF-Linear ở vài chi tiết (cách tính val, thứ tự lấy số ngẫu nhiên). Code gốc đã được chạy ở ETTh2 $H \in \{336, 720\}$ (Linear, DLinear), ở ETTm1 $H = 96$ DLinear trên CPU (MSE test 0,3018 $\pm$ 0,0010, 5 seed, so với số công bố 0,299), và ở cả 8 ô có số công bố thấp hơn mọi seed của repo, với `drop_last` của test loader bật và tắt (Bảng 6). Môi trường của chúng tôi (PyTorch 2.14.0, CUDA 13.0, GPU RTX 5060 Ti hoặc CPU, Windows 11) khác môi trường của bài gốc, và mỗi ô chỉ có 5 seed với code gốc. Với `drop_last=True`, số công bố nằm trong phân phối theo seed của code gốc ở 1/8 ô; ở các ô còn lại chúng tôi không đạt được số công bố, và `drop_last` không giải thích được khoảng chênh. Chúng tôi không kết luận số công bố là không tái lập được: khoảng chênh có thể đến từ môi trường, từ số seed hạn chế, hoặc từ chi tiết khác của lần chạy gốc mà repo không ghi lại.

9. **Độ chính xác của IRLS.** IRLS dừng theo ngưỡng giảm tương đối của hàm mục tiêu, nên nghiệm MAE là xấp xỉ. Trên ETTh1 $H = 96$, nghiệm từ ba điểm khởi tạo có cùng hàm mục tiêu tới sai số rất nhỏ, nhưng trọng số còn khác nhau do dừng sớm (Phụ lục B). MAE được tính qua Huber với $\delta = 10^{-6}$, tức một bản làm trơn của MAE.

10. **Metric trên dữ liệu đã chuẩn hóa.** Như LTSF-Linear, mọi MSE và MAE tính trên dữ liệu đã chuẩn hóa theo train (mục III.1), nên không đọc trực tiếp được theo đơn vị gốc của từng kênh, và các kênh có độ lệch chuẩn khác nhau được tính với trọng số như nhau.

11. **Commit ghi trong kết quả.** Một số JSON ghi commit có hậu tố `-dirty`, vì lúc chạy có file script hoặc báo cáo chưa commit. Code của solver và mô hình không đổi ở các commit đó; danh sách file cụ thể ghi trong từng báo cáo kỹ thuật ở `docs/reports/` (Phụ lục D).

VII. Kết luận

RQ1. Tại nghiệm tối ưu, DLinear thu về đúng Linear khi không có weight decay, vì hai nhánh xu hướng và mùa vụ cộng lại bằng chính đầu vào. Với weight decay, DLinear là ridge trong metric N^{-1} phụ thuộc kernel, nên tách khỏi Linear, nhưng ở λ^* chọn trên val mức tách trên test không quá 0,0016. NLinear là Linear có ràng buộc tổng hàng bằng 1, nên tách ở mọi λ. Ràng buộc này có lợi rõ trên ETTh2. Lợi thế của DLinear so với Linear trong các bảng công bố không xuất hiện ở nghiệm tối ưu, và khi huấn luyện bằng SGD thì biến mất sau khi tinh chỉnh learning rate.

RQ2. Trên dữ liệu gốc, huấn luyện bằng MAE cho MSE test thấp hơn huấn luyện bằng MSE ở 30/36 ô. Lợi thế lớn nhất ở ETTh2, nơi các đoạn cảm biến bị kẹt góp khoảng một nửa; NLinear trên ETTh2 là ngoại lệ. Huber với δ theo thang phần dư đứng giữa MSE và MAE ở phần lớn ô. MAE và Huber bền vững với outlier chỉ nằm ở đích. Khi outlier nằm trong chuỗi, chúng mất lợi thế khi outlier vừa nhiều vừa lớn.

RQ3. SGD với siêu tham số gốc kém nghiệm tối ưu trên test ở mọi ô của ETTh1 và ETTm1. Tinh chỉnh learning rate trên val không đóng được khoảng cách: SGD vẫn kém ở 27/36 ô (có ý nghĩa thống kê). SGD tốt hơn nghiệm tối ưu trên cả val lẫn test chỉ xảy ra trên ETTh2, với Linear và DLinear. Không giá trị λ nào của ridge, kể cả giá trị chọn theo test, đạt được mức đó, nên lợi thế này không phải một dạng chính quy hóa L2 mạnh hơn; cơ chế vẫn là câu hỏi mở. Các chênh lệch lớn giữa DLinear và Linear ở $H = 720$ trong bảng công bố nằm trong nhiễu theo seed của SGD. Chúng tôi không đạt được số công bố ở 8/36 ô, kể cả khi chạy code gốc trong môi trường của mình.

Tài liệu tham khảo

[1] A. Zeng et al., "Are transformers effective for time series forecasting?" In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2023.

[2] D. P. Kingma et al., "Adam: A method for stochastic optimization," in *International Conference on Learning Representations (ICLR)*, 2015.

[3] H. Zhou et al., "Informer: Beyond efficient transformer for long sequence time-series forecasting," in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2021.

[4] W. Toner et al., "An analysis of linear time series forecasting models," in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, 2024.

[5] P. J. Huber, "Robust estimation of a location parameter," *The Annals of Mathematical Statistics*, vol. 35, no. 1, pp. 73–101, 1964.

[6] P. J. Huber et al., *Robust Statistics*, 2nd ed. Wiley, 2009.

[7] P. W. Holland et al., "Robust regression using iteratively reweighted least-squares," *Communications in Statistics – Theory and Methods*, vol. 6, no. 9, pp. 813–827, 1977.

[8] A. Ali et al., "A continuous-time view of early stopping for least squares regression," in *Proceedings of the 22nd International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2019.

[9] C. M. Bishop, "Training with noise is equivalent to Tikhonov regularization," *Neural Computation*, vol. 7, no. 1, pp. 108–116, 1995.

Phụ lục

A. Dẫn xuất ba dự đoán của RQ1

Ký hiệu. $X \in \mathbb{R}^{n\times L}$, $Y \in \mathbb{R}^{n\times H}$ là đầu vào và đích train. Bias không bị phạt nên có thể loại bằng cách trừ trung bình: với mọi W_{eff}, bias tối ưu là $b = \bar{y} - W_{\text{eff}}\bar{x}$. Vì vậy từ đây giả sử X, Y đã được trừ trung bình theo cột, và đặt $A = X^\top X$, $C = X^\top Y$. Giả sử $A \succ 0$ (đúng trên cả ba dataset, vì $n \gg L$). Hàm mục tiêu MSE có phạt của Linear là

$$J(W) = \|Y - XW^\top\|_F^2 + \lambda \operatorname{tr}(W \operatorname{Pen} W^\top), \tag{7}$$

với nghiệm $W^\top = (A + \lambda \operatorname{Pen})^{-1} C$.

A.1. Dự đoán 1: DLinear trùng Linear khi $\lambda = 0$

Mệnh đề. Với mọi kernel k, tập các ánh xạ $\{W_{\text{eff}} = W_t P + W_s(I - P)\}$ của DLinear bằng toàn bộ $\mathbb{R}^{H\times L}$. Do đó, khi $\lambda = 0$, cực tiểu của DLinear và của Linear có cùng giá trị hàm mục tiêu và cùng W_{eff}.

Chứng minh. Với mọi $W \in \mathbb{R}^{H\times L}$, chọn $W_t = W_s = W$ thì $W_{\text{eff}} = WP + W(I - P) = W$. Vậy mọi ánh xạ của Linear đều đạt được bằng DLinear; chiều ngược lại hiển nhiên. Khi $\lambda = 0$, hàm mục tiêu chỉ phụ thuộc (W_{eff}, b). Hai bài toán vì vậy có cùng tập giá trị và cùng cực tiểu. Vì $A \succ 0$, W_{eff} tối ưu là duy nhất và bằng W_{OLS}. □

Về mặt đặc trưng, DLinear hồi quy trên $Z = [XP^\top,\ X(I - P)^\top] \in \mathbb{R}^{n\times 2L}$. Vì $z = (Px, (I - P)x)$ xác định được $x = Px + (I - P)x$ và ngược lại, $\operatorname{rank} Z = \operatorname{rank} X = L$. Đây là con số đo được ở Bảng 2. Nghiệm (W_t, W_s) vì vậy không duy nhất, nhưng W_{eff} thì duy nhất.

A.2. Dự đoán 2: DLinear tách khỏi Linear khi $\lambda > 0$

Weight decay của DLinear là $\lambda(\|W_t\|_F^2 + \|W_s\|_F^2)$.

Mệnh đề. Đặt $N = P^\top P + (I - P)^\top (I - P)$. Khi đó (i) $N \succeq \frac{1}{2} I$; (ii) với W_{eff} cố định,

$$\min_{W_t P + W_s(I-P) = W_{\text{eff}}} \|W_t\|_F^2 + \|W_s\|_F^2 = \operatorname{tr}(W_{\text{eff}} N^{-1} W_{\text{eff}}^\top); \tag{8}$$

(iii) DLinear có weight decay là ridge với $\operatorname{Pen} = N^{-1}$, tức $W_{\text{eff}}^\top = (A + \lambda N^{-1})^{-1} C$.

Chứng minh. (i) Với mọi v, $v^\top N v = \|Pv\|^2 + \|(I - P)v\|^2 \geq \frac{1}{2}\|Pv + (I - P)v\|^2 = \frac{1}{2}\|v\|^2$, theo bất đẳng thức $a^2 + b^2 \geq \frac{1}{2}(a + b)^2$ cho chuẩn. Vậy N khả nghịch và $N^{-1} \preceq 2I$.

(ii) Ràng buộc tách theo hàng. Với hàng h, gọi a, c là hàng h của W_t, W_s và w là hàng h của W_{eff}. Ràng buộc là $M \begin{bmatrix} a \\ c \end{bmatrix} = w$ với $M = [P^\top,\ (I - P)^\top] \in \mathbb{R}^{L\times 2L}$. Nghiệm chuẩn nhỏ nhất của hệ tuyến tính này có bình phương chuẩn $w^\top (MM^\top)^{-1} w$, và $MM^\top = N$. Cộng theo h được (ii).

(iii) Cực tiểu theo (W_t, W_s) bằng cực tiểu theo W_{eff} trước rồi theo cách tách: $\min_{W_{\text{eff}}} \|Y - XW_{\text{eff}}^\top\|_F^2 + \lambda \operatorname{tr}(W_{\text{eff}} N^{-1} W_{\text{eff}}^\top)$. Đây là ridge với $\operatorname{Pen} = N^{-1}$. □

Nghiệm này khác ridge đẳng hướng của Linear ($\operatorname{Pen} = I$) trừ khi $N \propto I$, mà N phụ thuộc k qua P. Vậy khi $\lambda > 0$, DLinear tách khỏi Linear, và mức tách phụ thuộc k. Phần tách không

xóa được bằng cách đổi thang λ, vì N^{-1} không tỉ lệ với I. Theo hướng đơn vị v, weight decay của DLinear bằng $v^\top N^{-1} v$ lần ridge đẳng hướng: nhẹ hơn ở các hướng mà P giữ lại gần nguyên vẹn (ví dụ trọng số trên giá trị gần nhất khi k lớn), và nặng hơn tới 2 lần ở tần số mà bộ lọc trung bình trượt cắt một nửa.

Lưu ý: tương đương (ii) chỉ dùng ràng buộc giữa (W_t, W_s) và W_{eff}, không dùng hàm mất mát. Nó vì vậy đúng với cả MAE và Huber, và bộ giải IRLS dùng $\text{Pen} = N^{-1}$ cho DLinear ở cả ba mục tiêu.

A.3. Dự đoán 3: NLinear tách khỏi Linear ở mọi λ

Theo (2), NLinear là Linear với ràng buộc $W_{\text{eff}} \mathbf{1}_L = \mathbf{1}_H$.

Mệnh đề ($\lambda = 0$). Đặt $r = W_{\text{OLS}} \mathbf{1}_L - \mathbf{1}_H$ (vi phạm tổng hàng của OLS), $u = A^{-1}\mathbf{1}_L$, $s = \mathbf{1}_L^\top u > 0$. Nghiệm NLinear là

$$V = W_{\text{OLS}} - \tfrac{1}{s}\, r\, u^\top, \tag{9}$$

và (i) $\|V - W_{\text{OLS}}\|_F = \|r\|\,\|u\|/s$; (ii) $\text{SSE}(V) - \text{SSE}(W_{\text{OLS}}) = \|r\|^2/s$.

Chứng minh. Bài toán tách theo hàng: với hàng h, cực tiểu $\|y_h - X v_h\|^2$ với điều kiện $\mathbf{1}^\top v_h = 1$. Điều kiện Lagrange cho $A v_h = c_h - \mu_h \mathbf{1}$, tức $v_h = w_h - \mu_h u$ với $w_h = A^{-1} c_h$. Từ $\mathbf{1}^\top v_h = 1$ suy ra $\mu_h = (\mathbf{1}^\top w_h - 1)/s = r_h/s$. Vậy $V - W_{\text{OLS}} = -\frac{1}{s} r u^\top$ có hạng 1, nên chuẩn Frobenius là $\|r\|\,\|u\|/s$. Với (ii), phần dư OLS trực giao với không gian cột của X, nên

$$\text{SSE}(V) - \text{SSE}(W_{\text{OLS}}) = \sum_h (v_h - w_h)^\top A (v_h - w_h) = \sum_h \frac{r_h^2}{s^2}\, u^\top A u = \frac{\|r\|^2}{s}. \qquad \square$$

Vậy NLinear trùng Linear khi và chỉ khi $r = 0$, tức nghiệm OLS đã có tổng hàng bằng đúng 1. Điều này không xảy ra trên dữ liệu: tổng hàng của OLS trên ETTh1 $H = 96$ giảm dần theo h, vì Linear kéo dự báo về trung bình train. Khi $\lambda > 0$, ràng buộc vẫn giữ nguyên nên hai nghiệm vẫn khác nhau. Khi $\lambda \to \infty$, Linear co về $W_{\text{eff}} = 0$ (dự báo bằng trung bình train), còn NLinear co về $W_{\text{eff}} = \mathbf{1}_H e_L^\top$ (lặp giá trị cuối). Hai giới hạn khác nhau, nên mức tách tăng theo λ (Hình 1).

A.4. Kiểm bằng module của LTSF-Linear

Notebook `notebooks/01_three_predictions.ipynb` kiểm cả ba mệnh đề trên ETTh1, $H = 96$, bằng ba bước. Thứ nhất, giải nghiệm dạng đóng trong chính tham số hóa của mô hình (DLinear trên (W_t, W_s) với đặc trưng do `series_decomp` của repo tạo ra; NLinear trên chuỗi đã trừ giá trị cuối). Thứ hai, nạp nghiệm vào module của repo và tính gradient bằng autograd. Hàm mục tiêu lồi, nên gradient bằng 0 là chứng nhận cực tiểu toàn cục. Thứ ba, đọc ánh xạ tuyến tính thật của module bằng các vector đơn vị, rồi so với Linear và với công thức ở trên. Kết quả ở Bảng 2.

B. IRLS cho MAE và Huber

B.1. Lập luận MM

Gọi $\tilde{X} = [X, \mathbf{1}] \in \mathbb{R}^{n \times p}$, $p = L + 1$ (cột cuối là bias), và $\tilde{w}_h \in \mathbb{R}^p$ là hàng h của ma trận hệ số. Hàm mục tiêu

$$F(W) = \sum_{i,h} \rho_\delta(r_{ih})/\delta + \lambda \sum_h w_h^\top \text{Pen}\, w_h, \qquad r_{ih} = y_{ih} - \tilde{x}_i^\top \tilde{w}_h, \tag{10}$$

lồi nhưng không khả vi bậc hai (MAE: không khả vi tại 0). IRLS là thuật toán majorize–minimize (MM). Tại phần dư hiện tại $r^{(0)}$, đặt trọng số $\omega = \delta/\max(|r^{(0)}|, \delta) \in (0, 1]$. Khi đó

$$\rho_\delta(r) \le \tfrac{\omega}{2}\, r^2 + \text{hằng số}, \quad \text{dấu bằng tại } r = r^{(0)}. \tag{11}$$

Thật vậy, nếu $|r^{(0)}| \le \delta$ thì $\omega = 1$ và $\rho_\delta(r) \le r^2/2$ với mọi r. Nếu $|r^{(0)}| > \delta$ thì $\delta|r| \le \delta\Big(r^2/(2|r^{(0)}|) + |r^{(0)}|/2\Big)$ theo bất đẳng thức AM–GM, và vế phải là $\frac{\omega}{2}r^2$ cộng hằng số. Cực tiểu hàm chặn trên (nhân 2δ) là một bài toán ridge có trọng số cho mỗi h:

$$\hat{\tilde{w}}_h = A_h^{-1}\tilde{X}^\top \operatorname{diag}(\omega_h)\, y_h, \qquad A_h = \tilde{X}^\top \operatorname{diag}(\omega_h)\tilde{X} + 2\lambda\delta\, \widetilde{\mathrm{Pen}}, \tag{12}$$

với $\widetilde{\mathrm{Pen}}$ là Pen thêm một hàng và một cột 0 cho bias. Vì mỗi bước cực tiểu một hàm chặn trên tiếp xúc tại điểm hiện tại, F không bao giờ tăng. Bộ giải báo lỗi nếu F tăng quá mức nhiễu làm tròn: điều đó nghĩa là code sai, hoặc A_h quá xấu điều kiện so với kiểu số đang dùng.

B.2. Các chi tiết cài đặt

- **Tách theo h.** Phần dư, trọng số và hàm phạt đều tách theo hàng h. Mỗi vòng vì vậy giải H hệ $p \times p$ độc lập, lập theo lô (`chunk` bước h một lần) trên GPU. Thực tế, mỗi vòng giải dạng hiệu chỉnh $\hat{\tilde{w}}_h = \tilde{w}_h + A_h^{-1} g_h$, với $g_h = \tilde{X}^\top \operatorname{diag}(\omega_h) r_h - 2\lambda\delta\, \widetilde{\mathrm{Pen}}\, \tilde{w}_h$.
- **Bias.** Cột $\mathbf{1}$ trong $\tilde{X}$; hàng và cột tương ứng của $\widetilde{\mathrm{Pen}}$ bằng 0, nên bias không bị phạt.
- **Ràng buộc NLinear.** Với $a = (1, \ldots, 1, 0)$ (tổng L hệ số đầu, không tính bias) và $u_h = A_h^{-1}a$, mỗi hàng được chiếu lên ràng buộc $a^\top v_h = 1$: $v_h = \hat{\tilde{w}}_h - \frac{a^\top \hat{\tilde{w}}_h - 1}{a^\top u_h} u_h$. Đây là nghiệm Lagrange của bước bình phương tối thiểu có trọng số, như ở Phụ lục A.
- **Quy ước λ.** Huber chia cho δ, nên khi $\delta \to 0$ ta được đúng $\sum|r| + \lambda\|W\|^2$ (MAE dùng $\delta = 10^{-6}$). Khi δ lớn, $F \approx \|r\|^2/(2\delta) + \lambda\|W\|^2$, tức ridge của MSE với $\lambda_{\mathrm{MSE}} = 2\delta\lambda$. Vì vậy λ^* của Huber tăng khi δ giảm.
- **Chế độ pha độ chính xác.** Phần tốn nhất là lập A_h (cỡ Hnp^2 phép tính), nên phần này làm bằng float32. Phần dư, g_h, hàm mục tiêu và phép giải làm bằng float64. Điểm dừng $g_h = 0$ tính bằng float64, nên nghiệm đạt độ chính xác float64; A_h lệch chỉ làm chậm hội tụ. Bước h nào làm hàm mục tiêu riêng của nó tăng thì được lập lại A_h bằng float64 và giải lại. Cách này không bao giờ chạy khi mọi bước đều tốt, nên không đổi kết quả trong trường hợp đó. TF32 bị tắt.
- **Tiêu chí dừng.** Dừng khi F giảm tương đối ít hơn `tol` sau `patience` vòng liên tiếp. MAE dùng `tol` $= 10^{-10}$, `patience` $= 1$, riêng $\lambda = 0$ dùng `tol` $= 3 \cdot 10^{-11}$. Huber dùng `tol` $= 10^{-9}$. Khởi tạo: nghiệm MSE cho $\lambda = 0$; nghiệm của λ liền trước khi quét λ (warm start).

B.3. Các phép kiểm

Chi tiết và số liệu ở `docs/reports/BAO_CAO_TIEU_CHI_DUNG.md`, `BAO_CAO_IRLS_DTYPE.md`, `BAO_CAO_5060TI.md` và `BAO_CAO_NV7.md`.

- **Trên dữ liệu giả** (`tests/test_irls.py`, `test_solvers.py`): Huber với δ lớn về đúng nghiệm ridge; MAE và NLinear MAE khớp nghiệm của quy hoạch tuyến tính; DLinear với $2L$ tham số khớp cách giải L chiều với Pen $= N^{-1}$.
- **Tính duy nhất của MAE** (ETTh1, $H = 96$): ba điểm khởi tạo cho cùng giá trị hàm mục tiêu dưới ngưỡng tương đối 10^{-8}. Trọng số còn khác nhau một chút, do dừng theo `tol`.
- **Tiêu chí dừng**: λ^* theo val giống nhau giữa khởi tạo lạnh, warm start, và nghiệm tham chiếu chạy tới hội tụ chặt. Sai số của metric val nhỏ hơn chênh giữa λ^* và λ tốt thứ hai.
- **Kiểu số**: float32 thuần không đủ cho MAE ($\delta = 10^{-6}$), vì hàm mục tiêu hết giảm được ở độ phân giải float32. Chế độ pha cho đúng nghiệm float64.
- **Grid**: mọi dòng của grid, thí nghiệm outlier, độ nhạy δ và độ lớn outlier đều có `converged = True`. Không có lần nào hàm mục tiêu tăng. Chạy lại một số đường λ bằng code hiện tại cho kết quả trùng từng bit với file kết quả.

C. Bảng đầy đủ

Mọi bảng trong phụ lục này sinh tự động bởi `scripts/report/make_tables.py` từ các file trong `results/` (xem `results/README.md`).

C.1. Nghiệm tối ưu, đủ mọi tổ hợp

Bảng 9 là bản đủ của Bảng 4, 216 ô: 3 mô hình × 3 mục tiêu × $\{\lambda = 0, \lambda^*\}$ × 3 dataset × 4 horizon, mỗi ô có cả MSE và MAE test.

Bảng 9: Nghiệm tối ưu, đủ mọi tổ hợp. Cột $\lambda = 0$: MSE / MAE test của nghiệm không phạt. MSE test ở λ^*_{MSE}, MAE test ở λ^*_{MAE}. Cột δ: δ_{MAD} của Huber; MAE là Huber với $\delta = 10^{-6}$. **Đậm**: thấp nhất giữa ba mục tiêu trong cùng (dataset, H, mô hình).

				$\lambda = 0$		MSE test		MAE test		
Dataset	H	Mô hình	Mục tiêu	MSE	MAE	λ^*_{MSE}	giá trị	λ^*_{MAE}	giá trị	δ
ETTh1	96	Linear	MSE	0,3702	0,3915	0	0,3702	141,3	0,3915	–
ETTh1	96	Linear	MAE	0,3653	0,3833	0	**0,3653**	0	**0,3833**	10^{-6}
ETTh1	96	Linear	Huber	0,3658	0,3852	3	0,3658	3	0,3852	0,538
ETTh1	96	DLinear	MSE	0,3702	0,3915	446,7	0,3698	446,7	0,3914	–
ETTh1	96	DLinear	MAE	0,3653	0,3833	300	**0,3647**	100	**0,3832**	10^{-6}
ETTh1	96	DLinear	Huber	0,3658	0,3852	300	0,3652	100	0,3851	0,538
ETTh1	96	NLinear	MSE	0,3702	0,3915	1413	0,3695	794,3	0,3913	–
ETTh1	96	NLinear	MAE	0,3662	0,3841	3000	**0,3638**	300	**0,3839**	10^{-6}
ETTh1	96	NLinear	Huber	0,3667	0,3861	1000	0,3656	300	0,3860	0,538
ETTh1	192	Linear	MSE	0,4042	0,4127	223,9	0,4040	199,5	0,4126	–
ETTh1	192	Linear	MAE	0,4047	0,4077	1000	0,4031	300	**0,4074**	10^{-6}
ETTh1	192	Linear	Huber	0,4030	0,4082	300	**0,4025**	30	0,4082	0,582
ETTh1	192	DLinear	MSE	0,4042	0,4127	1000	0,4036	562,3	0,4125	–
ETTh1	192	DLinear	MAE	0,4047	0,4077	3000	**0,4014**	300	**0,4074**	10^{-6}
ETTh1	192	DLinear	Huber	0,4030	0,4082	1000	0,4017	300	0,4080	0,582

				$\lambda = 0$		MSE test		MAE test		
Dataset	H	Mô hình	Mục tiêu	MSE	MAE	λ^*_{MSE}	giá trị	λ^*_{MAE}	giá trị	δ
ETTh1	192	NLinear	MSE	0,4034	0,4112	2512	0,4027	891,3	0,4110	–
ETTh1	192	NLinear	MAE	0,4064	0,4080	10^4	0,4026	1000	**0,4075**	10^{-6}
ETTh1	192	NLinear	Huber	0,4042	0,4085	3000	**0,4024**	300	0,4084	0,587
ETTh1	336	Linear	MSE	0,4334	0,4342	1995	0,4324	891,3	0,4340	–
ETTh1	336	Linear	MAE	0,4372	0,4283	$3 \cdot 10^4$	0,4302	1000	**0,4275**	10^{-6}
ETTh1	336	Linear	Huber	0,4343	0,4289	10^4	**0,4296**	1000	0,4285	0,621
ETTh1	336	DLinear	MSE	0,4334	0,4342	4467	0,4317	1585	0,4340	–
ETTh1	336	DLinear	MAE	0,4372	0,4283	$3 \cdot 10^4$	0,4296	3000	**0,4272**	10^{-6}
ETTh1	336	DLinear	Huber	0,4343	0,4289	10^4	**0,4290**	1000	0,4285	0,621
ETTh1	336	NLinear	MSE	0,4277	0,4262	8913	**0,4261**	1995	0,4260	–
ETTh1	336	NLinear	MAE	0,4361	0,4247	$3 \cdot 10^4$	0,4290	3000	**0,4237**	10^{-6}
ETTh1	336	NLinear	Huber	0,4327	0,4250	$3 \cdot 10^4$	0,4307	1000	0,4246	0,629
ETTh1	720	Linear	MSE	0,4714	0,4878	$1{,}778 \cdot 10^4$	0,4701	4467	0,4878	–
ETTh1	720	Linear	MAE	0,4568	0,4737	$3 \cdot 10^4$	**0,4553**	10^4	**0,4747**	10^{-6}
ETTh1	720	Linear	Huber	0,4586	0,4764	$3 \cdot 10^4$	0,4624	3000	0,4767	0,709
ETTh1	720	DLinear	MSE	0,4714	0,4878	$1{,}778 \cdot 10^4$	0,4697	5623	0,4879	–
ETTh1	720	DLinear	MAE	0,4568	0,4737	$3 \cdot 10^4$	**0,4549**	10^4	**0,4746**	10^{-6}
ETTh1	720	DLinear	Huber	0,4586	0,4764	$3 \cdot 10^4$	0,4620	3000	0,4766	0,709
ETTh1	720	NLinear	MSE	0,4344	0,4505	$1{,}995 \cdot 10^4$	0,4329	3981	0,4505	–
ETTh1	720	NLinear	MAE	0,4318	0,4445	$3 \cdot 10^4$	**0,4282**	10^4	**0,4454**	10^{-6}
ETTh1	720	NLinear	Huber	0,4314	0,4465	$3 \cdot 10^4$	0,4329	3000	0,4468	0,731
ETTh2	96	Linear	MSE	0,3019	0,3655	1585	0,3009	1413	0,3649	–
ETTh2	96	Linear	MAE	0,2789	0,3342	1000	**0,2779**	1000	**0,3334**	10^{-6}
ETTh2	96	Linear	Huber	0,2827	0,3417	1000	0,2818	1000	0,3410	0,398
ETTh2	96	DLinear	MSE	0,3019	0,3655	1995	0,3008	1585	0,3649	–
ETTh2	96	DLinear	MAE	0,2789	0,3342	1000	**0,2778**	1000	**0,3333**	10^{-6}
ETTh2	96	DLinear	Huber	0,2827	0,3417	1000	0,2817	1000	0,3410	0,398
ETTh2	96	NLinear	MSE	0,2726	0,3352	1778	**0,2717**	1585	0,3342	–
ETTh2	96	NLinear	MAE	0,2781	0,3317	3000	0,2764	1000	0,3307	10^{-6}
ETTh2	96	NLinear	Huber	0,2766	0,3316	1000	0,2756	1000	**0,3306**	0,372
ETTh2	192	Linear	MSE	0,3972	0,4276	1122	0,3966	1122	0,4273	–
ETTh2	192	Linear	MAE	0,3541	0,3861	1000	**0,3531**	1000	**0,3855**	10^{-6}
ETTh2	192	Linear	Huber	0,3609	0,3949	1000	0,3600	1000	0,3945	0,453
ETTh2	192	DLinear	MSE	0,3972	0,4276	1259	0,3966	1259	0,4273	–
ETTh2	192	DLinear	MAE	0,3541	0,3861	1000	**0,3531**	1000	**0,3855**	10^{-6}
ETTh2	192	DLinear	Huber	0,3609	0,3949	1000	0,3600	1000	0,3945	0,453
ETTh2	192	NLinear	MSE	0,3343	0,3762	1585	**0,3336**	1585	0,3754	–
ETTh2	192	NLinear	MAE	0,3464	0,3765	3000	0,3447	1000	0,3756	10^{-6}
ETTh2	192	NLinear	Huber	0,3437	0,3753	1000	0,3427	1000	**0,3744**	0,421
ETTh2	336	Linear	MSE	0,4858	0,4837	1000	0,4853	1000	0,4835	–
ETTh2	336	Linear	MAE	0,4116	0,4301	1000	**0,4106**	1000	**0,4296**	10^{-6}
ETTh2	336	Linear	Huber	0,4230	0,4404	1000	0,4220	1000	0,4400	0,505
ETTh2	336	DLinear	MSE	0,4858	0,4837	1122	0,4853	1122	0,4835	–
ETTh2	336	DLinear	MAE	0,4116	0,4301	1000	**0,4106**	1000	**0,4296**	10^{-6}
ETTh2	336	DLinear	Huber	0,4230	0,4404	1000	0,4220	1000	0,4400	0,505
ETTh2	336	NLinear	MSE	0,3588	0,4004	1585	**0,3581**	1413	**0,3997**	–
ETTh2	336	NLinear	MAE	0,3779	0,4039	3000	0,3760	1000	0,4028	10^{-6}
ETTh2	336	NLinear	Huber	0,3738	0,4018	1000	0,3727	1000	0,4008	0,470
ETTh2	720	Linear	MSE	0,7407	0,6116	1000	0,7404	1122	0,6115	–

				$\lambda = 0$		MSE test		MAE test		
Dataset	H	Mô hình	Mục tiêu	MSE	MAE	λ^*_{MSE}	giá trị	λ^*_{MAE}	giá trị	δ
ETTh2	720	Linear	MAE	0,5898	0,5337	1000	**0,5893**	1000	**0,5335**	10^{-6}
ETTh2	720	Linear	Huber	0,6280	0,5543	300	0,6277	300	0,5541	0,610
ETTh2	720	DLinear	MSE	0,7407	0,6116	1122	0,7403	1259	0,6115	–
ETTh2	720	DLinear	MAE	0,5898	0,5337	1000	**0,5892**	1000	**0,5335**	10^{-6}
ETTh2	720	DLinear	Huber	0,6280	0,5543	1000	0,6276	300	0,5541	0,610
ETTh2	720	NLinear	MSE	0,3930	0,4346	1995	0,3924	1585	0,4341	–
ETTh2	720	NLinear	MAE	0,3945	0,4255	3000	0,3926	1000	**0,4242**	10^{-6}
ETTh2	720	NLinear	Huber	0,3922	0,4259	1000	**0,3912**	1000	0,4251	0,587
ETTm1	96	Linear	MSE	0,2993	0,3428	631	0,2992	891,3	0,3427	–
ETTm1	96	Linear	MAE	0,2931	0,3332	1000	**0,2929**	1000	**0,3331**	10^{-6}
ETTm1	96	Linear	Huber	0,2954	0,3362	300	0,2953	300	0,3362	0,455
ETTm1	96	DLinear	MSE	0,2993	0,3428	1413	0,2992	1259	0,3427	–
ETTm1	96	DLinear	MAE	0,2931	0,3332	1000	**0,2929**	1000	**0,3331**	10^{-6}
ETTm1	96	DLinear	Huber	0,2954	0,3362	1000	0,2952	1000	0,3362	0,455
ETTm1	96	NLinear	MSE	0,3005	0,3426	5012	0,3004	2512	0,3426	–
ETTm1	96	NLinear	MAE	0,2941	0,3337	10^4	**0,2937**	3000	**0,3337**	10^{-6}
ETTm1	96	NLinear	Huber	0,2966	0,3367	3000	0,2964	1000	0,3367	0,453
ETTm1	192	Linear	MSE	0,3340	0,3637	354,8	0,3340	501,2	0,3637	–
ETTm1	192	Linear	MAE	0,3324	0,3554	1000	**0,3322**	300	**0,3553**	10^{-6}
ETTm1	192	Linear	Huber	0,3328	0,3578	300	0,3327	100	0,3578	0,497
ETTm1	192	DLinear	MSE	0,3340	0,3637	1122	0,3339	631	0,3637	–
ETTm1	192	DLinear	MAE	0,3324	0,3554	3000	**0,3319**	300	**0,3553**	10^{-6}
ETTm1	192	DLinear	Huber	0,3328	0,3578	1000	0,3326	300	0,3578	0,497
ETTm1	192	NLinear	MSE	0,3357	0,3634	5623	0,3356	1995	0,3634	–
ETTm1	192	NLinear	MAE	0,3343	0,3563	10^4	**0,3335**	3000	**0,3563**	10^{-6}
ETTm1	192	NLinear	Huber	0,3349	0,3586	10^4	0,3345	1000	0,3585	0,493
ETTm1	336	Linear	MSE	0,3684	0,3844	446,7	0,3683	354,8	0,3843	–
ETTm1	336	Linear	MAE	0,3659	0,3759	1000	**0,3658**	300	**0,3759**	10^{-6}
ETTm1	336	Linear	Huber	0,3662	0,3782	300	0,3661	10	0,3782	0,536
ETTm1	336	DLinear	MSE	0,3684	0,3844	1259	0,3683	446,7	0,3843	–
ETTm1	336	DLinear	MAE	0,3659	0,3759	3000	**0,3655**	300	**0,3759**	10^{-6}
ETTm1	336	DLinear	Huber	0,3662	0,3782	1000	0,3660	30	0,3782	0,536
ETTm1	336	NLinear	MSE	0,3704	0,3834	6310	0,3703	1585	0,3834	–
ETTm1	336	NLinear	MAE	0,3691	0,3770	10^4	**0,3685**	1000	**0,3770**	10^{-6}
ETTm1	336	NLinear	Huber	0,3694	0,3790	10^4	0,3691	1000	0,3790	0,534
ETTm1	720	Linear	MSE	0,4233	0,4181	1259	0,4232	631	0,4181	–
ETTm1	720	Linear	MAE	0,4218	0,4102	1000	0,4216	1000	**0,4101**	10^{-6}
ETTm1	720	Linear	Huber	0,4210	0,4121	300	**0,4210**	100	0,4120	0,589
ETTm1	720	DLinear	MSE	0,4233	0,4181	2512	0,4232	794,3	0,4181	–
ETTm1	720	DLinear	MAE	0,4218	0,4102	3000	0,4213	1000	**0,4101**	10^{-6}
ETTm1	720	DLinear	Huber	0,4210	0,4121	1000	**0,4208**	100	0,4121	0,589
ETTm1	720	NLinear	MSE	0,4263	0,4157	7079	**0,4262**	1585	0,4157	–
ETTm1	720	NLinear	MAE	0,4281	0,4114	$3 \cdot 10^4$	0,4270	1000	**0,4113**	10^{-6}
ETTm1	720	NLinear	Huber	0,4267	0,4126	10^4	0,4264	300	0,4126	0,589

C.2. SGD so với nghiệm dạng đóng, từng ô

Bảng 10 cho Δ test và nhãn của từng ô, với lr gốc (20 seed) và lr đã tinh chỉnh (15 seed mới). Bảng 11 cho MSE val của từng mức lr đã thử.

Bảng 10: Δ = TB SGD − dạng đóng MSE ở λ^*, MSE test, CI 95% theo t. Nhãn theo mã của Bảng 1: T1 SGD tốt hơn thật; T2 dạng đóng tốt hơn thật; T3 khác biệt do val khác test; T4 SGD có dấu hiệu khớp val quá mức; T5 dạng đóng có dấu hiệu khớp val quá mức; T6 không phân biệt được. Cột lr: mức được chọn, bội của lr gốc.

			lr gốc, 20 seed		lr tinh chỉnh, 15 seed		
Dataset	H	Mô hình	Δ test [CI 95%]	nhãn	lr	Δ test [CI 95%]	nhãn
ETTh1	96	Linear	+0,0083 [0,0033; 0,0133]	T4	×4	+0,0060 [0,0029; 0,0091]	T4
ETTh1	96	DLinear	+0,0067 [0,0041; 0,0094]	T4	×1	+0,0067 [0,0034; 0,0100]	T4
ETTh1	96	NLinear	+0,0084 [0,0050; 0,0118]	T3	×4	+0,0067 [0,0037; 0,0097]	T4
ETTh1	192	Linear	+0,0211 [0,0107; 0,0315]	T4	×8	+0,0216 [0,0057; 0,0374]	T3
ETTh1	192	DLinear	+0,0110 [0,0039; 0,0181]	T4	×2	+0,0075 [0,0038; 0,0111]	T3
ETTh1	192	NLinear	+0,0078 [0,0028; 0,0127]	T3	×4	+0,0084 [−0,0004; 0,0173]	T6
ETTh1	336	Linear	+0,0229 [0,0141; 0,0318]	T4	×1	+0,0259 [0,0142; 0,0375]	T4
ETTh1	336	DLinear	+0,0256 [0,0105; 0,0406]	T4	×0,5	+0,0222 [0,0074; 0,0371]	T4
ETTh1	336	NLinear	+0,0059 [0,0039; 0,0078]	T2	×2	+0,0039 [0,0024; 0,0055]	T3
ETTh1	720	Linear	+0,0363 [0,0193; 0,0532]	T4	×0,5	+0,0290 [0,0178; 0,0402]	T4
ETTh1	720	DLinear	+0,0400 [0,0214; 0,0585]	T3	×8	+0,0198 [0,0100; 0,0296]	T3
ETTh1	720	NLinear	+0,0034 [0,0027; 0,0041]	T2	×2	+0,0025 [0,0022; 0,0028]	T2
ETTh2	96	Linear	−0,0041 [−0,0130; 0,0049]	T4	×1	−0,0020 [−0,0136; 0,0095]	T6
ETTh2	96	DLinear	−0,0095 [−0,0123; −0,0067]	T1	×1	−0,0083 [−0,0111; −0,0054]	T1
ETTh2	96	NLinear	+0,0053 [0,0039; 0,0067]	T2	×0,5	+0,0052 [0,0036; 0,0068]	T2
ETTh2	192	Linear	−0,0005 [−0,0226; 0,0216]	T6	×4	−0,0025 [−0,0280; 0,0230]	T6
ETTh2	192	DLinear	−0,0159 [−0,0227; −0,0091]	T1	×0,5	−0,0220 [−0,0301; −0,0138]	T1
ETTh2	192	NLinear	+0,0108 [0,0079; 0,0137]	T3	×0,25	+0,0137 [0,0101; 0,0173]	T4
ETTh2	336	Linear	−0,0357 [−0,0470; −0,0245]	T1	×1	−0,0345 [−0,0476; −0,0215]	T1
ETTh2	336	DLinear	−0,0325 [−0,0438; −0,0212]	T1	×1	−0,0338 [−0,0469; −0,0207]	T1
ETTh2	336	NLinear	+0,0223 [0,0123; 0,0322]	T3	×0,5	+0,0191 [0,0106; 0,0275]	T3
ETTh2	720	Linear	−0,0437 [−0,0663; −0,0211]	T1	×0,5	−0,0314 [−0,0750; 0,0122]	T6
ETTh2	720	DLinear	−0,0534 [−0,0811; −0,0257]	T1	×1	−0,0507 [−0,0805; −0,0209]	T1
ETTh2	720	NLinear	+0,0134 [0,0047; 0,0221]	T3	×0,125	+0,0151 [0,0100; 0,0202]	T3
ETTm1	96	Linear	+0,0065 [0,0056; 0,0074]	T2	×32	+0,0020 [0,0005; 0,0035]	T4
ETTm1	96	DLinear	+0,0025 [0,0016; 0,0033]	T3	×2	+0,0025 [0,0011; 0,0039]	T4
ETTm1	96	NLinear	+0,0086 [0,0067; 0,0106]	T2	×8	+0,0047 [0,0026; 0,0068]	T4
ETTm1	192	Linear	+0,0062 [0,0056; 0,0067]	T2	×8	+0,0031 [0,0015; 0,0048]	T4
ETTm1	192	DLinear	+0,0030 [0,0022; 0,0037]	T4	×2	+0,0022 [0,0014; 0,0029]	T4
ETTm1	192	NLinear	+0,0080 [0,0067; 0,0093]	T2	×4	+0,0063 [0,0037; 0,0089]	T3
ETTm1	336	Linear	+0,0086 [0,0074; 0,0097]	T2	×8	+0,0084 [0,0039; 0,0128]	T4
ETTm1	336	DLinear	+0,0049 [0,0036; 0,0061]	T4	×4	+0,0064 [0,0032; 0,0097]	T4
ETTm1	336	NLinear	+0,0076 [0,0066; 0,0087]	T2	×4	+0,0070 [0,0031; 0,0109]	T3
ETTm1	720	Linear	+0,0104 [0,0085; 0,0122]	T4	×2	+0,0100 [0,0069; 0,0131]	T4
ETTm1	720	DLinear	+0,0057 [0,0044; 0,0070]	T4	×2	+0,0080 [0,0056; 0,0104]	T4
ETTm1	720	NLinear	+0,0084 [0,0069; 0,0098]	T2	×16	+0,0041 [0,0019; 0,0062]	T4

Bảng 11: Tinh chỉnh learning rate: MSE val trung bình trên 5 seed (2021–2025) cho từng mức lr. **Đậm**: mức được chọn. "–": không thử (×8 chỉ thử khi ×4 được chọn; ×0,25, ×0,125, ×16, ×32 chỉ thử ở ô chọn mức đầu mút, theo quy tắc ở mục III.6).

				MSE val trung bình (seed 2021–2025), lr = × lr gốc									
Dataset	H	Mô hình	lr gốc	×0,125	×0,25	×0,5	×1	×2	×4	×8	×16	×32	chọn
ETTh2	96	Linear	0,05	–	–	0,2154	**0,2151**	0,2165	0,2158	–	–	–	×1
ETTh2	192	Linear	0,05	–	–	0,3063	0,3038	0,3095	**0,2960**	0,2978	–	–	×4
ETTh2	336	Linear	0,05	–	–	0,4006	**0,3946**	0,3956	0,3967	–	–	–	×1
ETTh2	720	Linear	0,05	–	0,6559	**0,6531**	0,6557	0,6549	0,6558	–	–	–	×0,5
ETTh2	96	DLinear	0,05	–	–	0,2174	**0,2156**	0,2161	0,2170	–	–	–	×1
ETTh2	192	DLinear	0,05	–	0,2963	**0,2958**	0,2980	0,3005	0,3017	–	–	–	×0,5
ETTh2	336	DLinear	0,05	–	–	0,3963	**0,3962**	0,3985	0,4003	–	–	–	×1
ETTh2	720	DLinear	0,05	–	–	0,6613	**0,6612**	0,6613	0,6623	–	–	–	×1
ETTh2	96	NLinear	0,05	–	0,2055	**0,2055**	0,2060	0,2080	0,2147	–	–	–	×0,5
ETTh2	192	NLinear	0,05	0,2711	**0,2702**	0,2708	0,2720	0,2772	0,2976	–	–	–	×0,25
ETTh2	336	NLinear	0,05	–	0,3602	**0,3586**	0,3606	0,3638	0,3703	–	–	–	×0,5
ETTh2	720	NLinear	0,05	**0,6013**	0,6036	0,6037	0,6099	0,6073	0,6150	–	–	–	×0,125
ETTh1	96	Linear	0,005	–	–	0,6503	0,6486	0,6462	**0,6448**	0,6597	–	–	×4
ETTh1	192	Linear	0,005	–	–	0,8655	0,8661	0,8645	0,8593	**0,8563**	0,8569	–	×8
ETTh1	336	Linear	0,005	–	–	1,0526	**1,0415**	1,0416	1,0445	–	–	–	×1
ETTh1	720	Linear	0,005	–	1,2081	**1,1960**	1,2075	1,2131	1,2001	–	–	–	×0,5
ETTh1	96	DLinear	0,005	–	–	0,6487	**0,6480**	0,6483	0,6487	–	–	–	×1
ETTh1	192	DLinear	0,005	–	–	0,8728	0,8643	**0,8543**	0,8565	–	–	–	×2
ETTh1	336	DLinear	0,005	–	1,0511	**1,0450**	1,0525	1,0493	1,0728	–	–	–	×0,5
ETTh1	720	DLinear	0,005	–	–	1,2133	1,2223	1,2399	1,2032	**1,2030**	1,2065	–	×8
ETTh1	96	NLinear	0,005	–	–	0,6681	0,6771	0,6822	**0,6673**	0,6676	–	–	×4
ETTh1	192	NLinear	0,005	–	–	0,9165	0,9210	0,9129	**0,9127**	0,9130	–	–	×4
ETTh1	336	NLinear	0,005	–	–	1,1568	1,1543	**1,1524**	1,1531	–	–	–	×2
ETTh1	720	NLinear	0,005	–	–	1,4308	1,4292	**1,4291**	1,4292	–	–	–	×2
ETTm1	96	Linear	0,0001	–	–	0,3922	0,3879	0,3846	0,3820	0,3815	0,3813	**0,3812**	×32
ETTm1	192	Linear	0,0001	–	–	0,4993	0,4945	0,4914	0,4913	**0,4888**	0,4890	–	×8
ETTm1	336	Linear	0,0001	–	–	0,6251	0,6198	0,6164	0,6118	**0,6106**	0,6163	–	×8
ETTm1	720	Linear	0,0001	–	–	0,8762	0,8686	**0,8612**	0,8617	–	–	–	×2
ETTm1	96	DLinear	0,0001	–	–	0,3846	0,3826	**0,3813**	0,3817	–	–	–	×2
ETTm1	192	DLinear	0,0001	–	–	0,4922	0,4892	**0,4879**	0,4879	–	–	–	×2
ETTm1	336	DLinear	0,0001	–	–	0,6173	0,6152	0,6142	**0,6135**	0,6177	–	–	×4
ETTm1	720	DLinear	0,0001	–	–	0,8681	0,8618	**0,8524**	0,8563	–	–	–	×2
ETTm1	96	NLinear	0,0001	–	–	0,3958	0,3928	0,3903	0,3877	**0,3845**	0,3873	–	×8
ETTm1	192	NLinear	0,0001	–	–	0,5130	0,5096	0,5060	**0,5046**	0,5051	–	–	×4
ETTm1	336	NLinear	0,0001	–	–	0,6574	0,6539	0,6519	**0,6503**	0,6513	–	–	×4
ETTm1	720	NLinear	0,0001	–	–	0,9678	0,9649	0,9625	0,9614	0,9607	**0,9582**	0,9585	×16

C.3. Họ ridge trên ETTh2

Bảng 12 so họ ridge (mục tiêu MSE, đủ 142 giá trị λ) với SGD trên ETTh2 (mục IV.3).

Bảng 12: Họ ridge so với SGD trên ETTh2, MSE test. †Ridge tốt nhất theo test: MSE test nhỏ nhất trên toàn lưới λ, tức chọn λ bằng tập test. Đây là *mức tham chiếu không hợp lệ để chọn mô hình*, chỉ dùng để chỉ ra giới hạn dưới của cả họ ridge. SGD: lr gốc 20 seed, lr tinh chỉnh 15 seed.

		ridge ở λ^*_{MSE} (theo val)		ridge tốt nhất theo test†		$\lambda = 0$	SGD, TB theo seed	
Mô hình	H	λ	test	λ	test	test	lr gốc	tinh chỉnh
Linear	96	1585	0,3009	1995	0,3009	0,3019	0,2968	0,2989
Linear	192	1122	0,3966	1585	0,3966	0,3972	0,3961	0,3941
Linear	336	1000	0,4853	1585	0,4853	0,4858	0,4496	0,4508
Linear	720	1000	0,7404	1000	0,7404	0,7407	0,6967	0,7089
DLinear	96	1995	0,3008	2818	0,3007	0,3019	0,2913	0,2925
DLinear	192	1259	0,3966	1995	0,3965	0,3972	0,3807	0,3746
DLinear	336	1122	0,4853	1778	0,4853	0,4858	0,4529	0,4515
DLinear	720	1122	0,7403	1122	0,7403	0,7407	0,6869	0,6897

C.4. Vị trí các đoạn hằng của ETTh2

Bảng 13 liệt kê các đoạn hằng dài ít nhất 96 giờ của ETTh2 (mục IV.4).

Bảng 13: Các đoạn của ETTh2 mà một kênh giữ nguyên giá trị gốc ít nhất 96 giờ liên tiếp (đủ dài để tạo cửa sổ đích hằng ở $H = 96$). Giá trị theo đơn vị gốc. Cột "thuộc": train, val hay test theo cách chia ở mục III.1.

Kênh	bắt đầu	kết thúc	số giờ	giá trị	thuộc
HULL	2017-09-16 23h	2017-09-23 07h	153	0,00	val
HULL	2017-10-25 23h	2017-10-30 09h	107	0,00	test
HULL	2017-10-30 11h	2017-11-08 20h	226	0,00	test
HULL	2017-11-14 22h	2017-11-19 20h	119	0,00	test
HULL	2017-11-19 22h	2017-11-24 11h	110	0,00	test
HULL	2017-11-24 13h	2017-11-28 15h	99	0,00	test
HULL	2017-12-30 03h	2018-01-03 18h	112	0,00	test
MUFL	2017-04-19 19h	2017-06-01 11h	1025	88,30	train
LUFL	2017-01-23 23h	2017-02-08 16h	378	2,16	train
LUFL	2017-04-10 08h	2017-04-14 22h	111	0,00	train
LULL	2016-07-13 19h	2016-07-23 14h	236	0,00	train
LULL	2016-08-20 06h	2016-09-05 04h	383	0,00	train
LULL	2017-01-21 20h	2017-02-09 16h	453	0,00	train
LULL	2017-03-12 16h	2017-03-27 06h	351	0,00	train
LULL	2017-03-27 08h	2017-04-13 16h	417	0,00	train
LULL	2017-04-13 18h	2017-04-24 10h	257	−31,46	train
LULL	2017-04-24 12h	2017-05-15 10h	503	−28,16	train
LULL	2018-01-07 15h	2018-01-12 09h	115	0,00	test
LULL	2018-02-10 13h	2018-02-14 22h	106	−2,55	test

C.5. Huber với δ theo từng bước h

Bảng 14 so Huber với $\delta_h = 1{,}345\,\hat{\sigma}_h$ theo từng bước và Huber với δ_{MAD} chung (mục IV.2).

Bảng 14: Huber với δ chung (δ_{MAD}) và δ theo bước ($\delta_h = 1{,}345\,\hat{\sigma}_h$, $\hat{\sigma}_h = 1{,}4826 \cdot \text{MAD}$ của phần dư train ở bước h của nghiệm MSE $\lambda = 0$), đặt cạnh mục tiêu MSE và MAE của cùng ô. MSE test ở λ^*_{MSE}, MAE test ở λ^*_{MAE} của từng đường λ. Đường λ đầy đủ như grid, `tol` $= 10^{-9}$.

Ô	metric	mục tiêu huấn luyện MSE	MAE	Huber, δ_{MAD}	Huber, δ_h
ETTh1, $H = 96$, Linear	MSE test	0,3702	0,3653	0,3658	0,3656
	MAE test	0,3915	0,3833	0,3852	0,3851
ETTh2, $H = 720$, Linear	MSE test	0,7404	0,5893	0,6277	0,6357
	MAE test	0,6115	0,5335	0,5541	0,5566

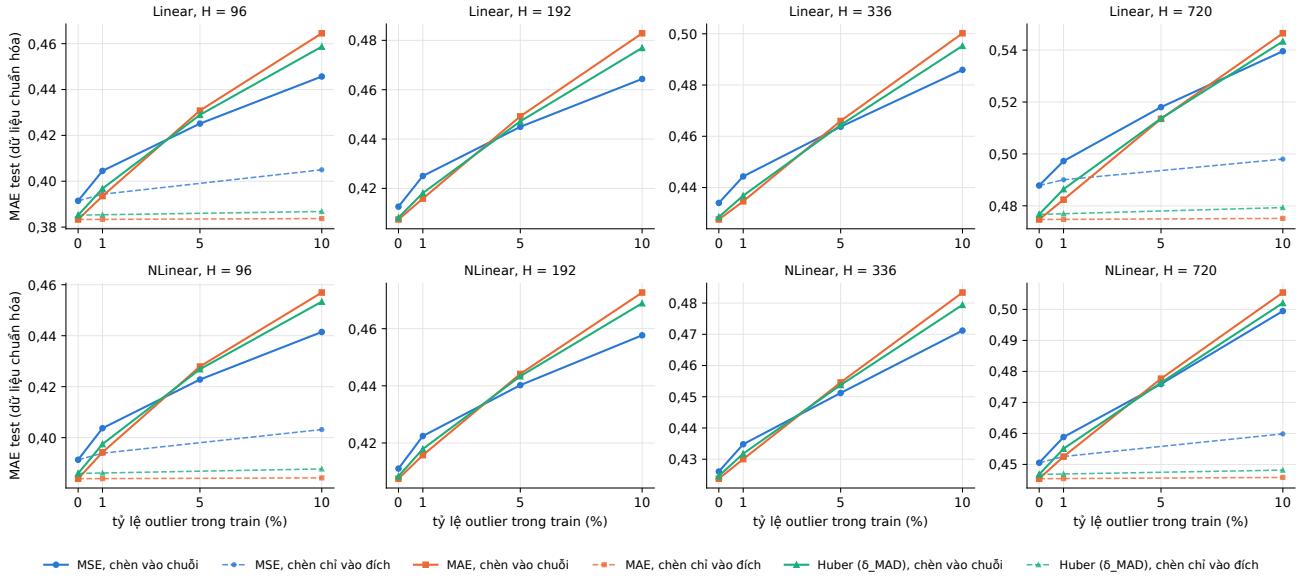
C.6. Thí nghiệm outlier

Bảng 15 cho bảng đầy đủ của thí nghiệm outlier (±10 độ lệch chuẩn, seed 2026), và Hình 7 là bản theo MAE test của Hình 3. Bảng 16 cho thí nghiệm độ lớn.

Bảng 15: Outlier trên ETTh1, ±10 độ lệch chuẩn, seed 2026. "chuỗi": chèn vào chuỗi train; "đích": chèn chỉ vào đích. Huber dùng δ_{MAD} của chính tập train đã chèn. **Đậm**: thấp nhất giữa ba mục tiêu.

			MSE test ở λ^*_{MSE}			MAE test ở λ^*_{MAE}		
Mô hình	H	chèn, tỷ lệ	MSE	MAE	Huber	MSE	MAE	Huber
Linear	96	gốc	0,3702	**0,3653**	0,3658	0,3915	**0,3833**	0,3852
Linear	96	chuỗi, 1%	0,3818	**0,3688**	0,3731	0,4045	**0,3935**	0,3968
Linear	96	chuỗi, 5%	**0,4110**	0,4230	0,4197	**0,4251**	0,4308	0,4289
Linear	96	chuỗi, 10%	**0,4445**	0,4790	0,4691	**0,4457**	0,4645	0,4587
Linear	96	đích, 1%	0,3727	**0,3654**	0,3659	0,3943	**0,3834**	0,3854
Linear	96	đích, 10%	0,3841	**0,3651**	0,3667	0,4050	**0,3837**	0,3868
Linear	192	gốc	0,4040	0,4031	**0,4025**	0,4126	**0,4074**	0,4082
Linear	192	chuỗi, 1%	0,4148	**0,4051**	0,4078	0,4250	**0,4159**	0,4181
Linear	192	chuỗi, 5%	**0,4414**	0,4523	0,4491	**0,4449**	0,4492	0,4472
Linear	192	chuỗi, 10%	**0,4736**	0,5069	0,4968	**0,4644**	0,4829	0,4769
Linear	336	gốc	0,4324	0,4302	**0,4296**	0,4340	**0,4275**	0,4285
Linear	336	chuỗi, 1%	0,4380	**0,4303**	0,4322	0,4443	**0,4346**	0,4368
Linear	336	chuỗi, 5%	**0,4615**	0,4697	0,4670	**0,4637**	0,4660	0,4644
Linear	336	chuỗi, 10%	**0,4988**	0,5237	0,5149	**0,4859**	0,5002	0,4953
Linear	720	gốc	0,4701	**0,4553**	0,4624	0,4878	**0,4747**	0,4767
Linear	720	chuỗi, 1%	0,4765	**0,4578**	0,4629	0,4972	**0,4824**	0,4864
Linear	720	chuỗi, 5%	0,5050	0,5032	**0,5024**	0,5180	**0,5135**	0,5137
Linear	720	chuỗi, 10%	**0,5470**	0,5597	0,5527	**0,5396**	0,5465	0,5433
Linear	720	đích, 1%	0,4716	**0,4554**	0,4629	0,4900	**0,4748**	0,4769
Linear	720	đích, 10%	0,4798	**0,4562**	0,4596	0,4980	**0,4751**	0,4793
NLinear	96	gốc	0,3695	**0,3638**	0,3656	0,3913	**0,3839**	0,3860
NLinear	96	chuỗi, 1%	0,3812	**0,3692**	0,3734	0,4037	**0,3942**	0,3975
NLinear	96	chuỗi, 5%	**0,4087**	0,4194	0,4172	**0,4228**	0,4279	0,4269
NLinear	96	chuỗi, 10%	**0,4405**	0,4688	0,4624	**0,4415**	0,4569	0,4534
NLinear	96	đích, 1%	0,3715	**0,3638**	0,3657	0,3939	**0,3839**	0,3861
NLinear	96	đích, 10%	0,3808	**0,3638**	0,3667	0,4032	**0,3842**	0,3877
NLinear	192	gốc	0,4027	0,4026	**0,4024**	0,4110	**0,4075**	0,4084
NLinear	192	chuỗi, 1%	0,4133	**0,4056**	0,4080	0,4224	**0,4157**	0,4179
NLinear	192	chuỗi, 5%	**0,4376**	0,4472	0,4453	**0,4402**	0,4442	0,4434
NLinear	192	chuỗi, 10%	**0,4680**	0,4949	0,4880	**0,4577**	0,4727	0,4689
NLinear	336	gốc	**0,4261**	0,4290	0,4307	0,4260	**0,4237**	0,4246

			MSE test ở λ^*_{MSE}			MAE test ở λ^*_{MAE}		
Mô hình	H	chèn, tỷ lệ	MSE	MAE	Huber	MSE	MAE	Huber
NLinear	336	chuỗi, 1%	0,4309	**0,4275**	0,4289	0,4348	**0,4300**	0,4318
NLinear	336	chuỗi, 5%	**0,4507**	0,4586	0,4569	**0,4512**	0,4546	0,4538
NLinear	336	chuỗi, 10%	**0,4852**	0,5047	0,4982	**0,4712**	0,4834	0,4794
NLinear	720	gốc	0,4329	**0,4282**	0,4329	0,4505	**0,4454**	0,4468
NLinear	720	chuỗi, 1%	0,4368	**0,4287**	0,4314	0,4588	**0,4525**	0,4551
NLinear	720	chuỗi, 5%	**0,4580**	0,4607	0,4588	**0,4759**	0,4777	0,4764
NLinear	720	chuỗi, 10%	**0,5003**	0,5072	0,5019	**0,4995**	0,5055	0,5020
NLinear	720	đích, 1%	0,4343	**0,4283**	0,4332	0,4526	**0,4454**	0,4469
NLinear	720	đích, 10%	0,4420	**0,4289**	0,4297	0,4599	**0,4458**	0,4482



Hình 7: Như Hình 3 nhưng là MAE test ở λ^*_{MAE} (chọn theo MAE val sạch).

Bảng 16: Độ lớn outlier: Linear, ETTh1, seed 2026, cùng vị trí outlier ở mọi độ lớn. **Đậm**: thấp nhất giữa ba mục tiêu.

				MSE test ở λ^*_{MSE}			MAE test ở λ^*_{MAE}		
H	chèn	tỷ lệ	độ lớn	MSE	MAE	Huber	MSE	MAE	Huber
96	gốc	–	–	0,3702	**0,3653**	0,3658	0,3915	**0,3833**	0,3852
96	chuỗi	1%	3σ	0,3700	**0,3622**	0,3643	0,3924	**0,3831**	0,3857
96	chuỗi	1%	5σ	0,3720	**0,3620**	0,3650	0,3952	**0,3851**	0,3880
96	chuỗi	1%	10σ	0,3818	**0,3688**	0,3731	0,4045	**0,3935**	0,3968
96	chuỗi	10%	3σ	0,3799	**0,3745**	0,3757	0,4026	**0,3979**	0,3990
96	chuỗi	10%	5σ	**0,3954**	0,3969	0,3958	0,4144	0,4144	**0,4138**
96	chuỗi	10%	10σ	**0,4445**	0,4790	0,4691	**0,4457**	0,4645	0,4587
96	đích	1%	3σ	0,3705	**0,3654**	0,3659	0,3918	**0,3834**	0,3853
96	đích	1%	5σ	0,3709	**0,3654**	0,3659	0,3924	**0,3834**	0,3853
96	đích	1%	10σ	0,3727	**0,3654**	0,3659	0,3943	**0,3834**	0,3854
96	đích	10%	3σ	0,3721	**0,3651**	0,3667	0,3939	**0,3836**	0,3862
96	đích	10%	5σ	0,3750	**0,3651**	0,3668	0,3967	**0,3837**	0,3863
96	đích	10%	10σ	0,3841	**0,3651**	0,3667	0,4050	**0,3837**	0,3868
720	gốc	–	–	0,4701	**0,4553**	0,4624	0,4878	**0,4747**	0,4767
720	chuỗi	1%	3σ	0,4704	**0,4566**	0,4573	0,4887	**0,4757**	0,4772
720	chuỗi	1%	5σ	0,4712	**0,4584**	0,4589	0,4902	**0,4746**	0,4786
720	chuỗi	1%	10σ	0,4765	**0,4578**	0,4629	0,4972	**0,4824**	0,4864
720	chuỗi	10%	3σ	0,4757	**0,4627**	0,4644	0,4957	**0,4844**	0,4876
720	chuỗi	10%	5σ	0,4904	**0,4814**	0,4830	0,5065	**0,5004**	0,5014
720	chuỗi	10%	10σ	**0,5470**	0,5597	0,5527	**0,5396**	0,5465	0,5433
720	đích	1%	3σ	0,4702	**0,4554**	0,4628	0,4881	**0,4748**	0,4769
720	đích	1%	5σ	0,4706	**0,4554**	0,4628	0,4885	**0,4748**	0,4769
720	đích	1%	10σ	0,4716	**0,4554**	0,4629	0,4900	**0,4748**	0,4769
720	đích	10%	3σ	0,4714	**0,4562**	0,4584	0,4898	**0,4751**	0,4784
720	đích	10%	5σ	0,4734	**0,4562**	0,4586	0,4919	**0,4751**	0,4785
720	đích	10%	10σ	0,4798	**0,4562**	0,4596	0,4980	**0,4751**	0,4793

D. Tái lập

D.1. Môi trường và phần cứng

- Python 3.13.5. Thư viện (`requirements.txt`): numpy 2.3.1, pandas 2.3.1, scipy 1.18.1, matplotlib 3.11.0, scikit-learn 1.9.0.
- PyTorch 2.14.0. Bản `+cu130` cho GPU RTX 50xx (Blackwell cần CUDA $\geq$ 12.8); bản CPU nếu không có GPU. Cài torch *trước* `requirements.txt`, xem `README.md`.
- GPU (grid, IRLS, code gốc LTSF-Linear): NVIDIA RTX 5060 Ti 16 GB, driver 616.92, CUDA 13.0, TF32 tắt. CPU (SGD): Intel 12 luồng. Hệ điều hành Windows 11; lệnh chạy qua Git Bash.

D.2. Seed

- SGD với lr gốc: seed 2021–2040 (NLinear trên ETTh2: 2021–2030).

- SGD tinh chỉnh lr: chọn lr bằng seed 2021–2025, chạy cuối bằng seed 2026–2040 (không trùng seed chọn lr).
- Code gốc LTSF-Linear (có và không `drop_last`): seed 2021–2025.
- Vị trí outlier: seed 2026; thêm 2027, 2028 ở ETTh1 $H = 96$ Linear.

D.3. Lệnh

Tái lập

```
git clone --recurse-submodules <repo> && cd dlinear-objective-lab
./run_all.sh quick   # tests, re-run one grid cell, regenerate numbers/tables/figures, build PDF
./run_all.sh full    # re-run every experiment (many GPU/CPU hours)
```

Chế độ `quick` chạy lại toàn bộ grid của ETTh1 $H = 96$ (3 mô hình, 3 mục tiêu) vào một thư mục tạm, rồi so với `results/lambda_path.csv` bằng `scripts/checks/compare_cell.py`. Ngưỡng là 10^{-10} với MSE và 10^{-8} với MAE, Huber. Trên máy ở trên, bước này mất khoảng 14 phút. Chế độ `full` chạy theo thứ tự: grid, λ^*, Huber δ_{MAD}, outlier, SGD, tinh chỉnh lr và mở rộng lưới lr, code gốc với `drop_last`, Huber với δ theo bước. Thời gian từng bước, giá trị mong đợi của ô kiểm và lệnh chi tiết nằm trong `README.md` và mục "Tái lập" của từng báo cáo kỹ thuật ở `docs/reports/`. Đường dẫn cũ trong các báo cáo đó tra ở `docs/DUONG_DAN_CU.md`.

D.4. Thời gian chạy đã đo

- Grid (MSE dạng đóng, MAE và Huber $\delta = 1$ bằng IRLS, GPU): 14,6 giờ, gồm ETTh1 3,5, ETTh2 3,9 và ETTm1 7,3 giờ. MAE chiếm gần hết thời gian.
- Grid Huber δ_{MAD} (GPU): 0,6 giờ.
- SGD với lr gốc (CPU, tổng thời gian của các lần chạy, 20 seed): 5,5 giờ.
- Tinh chỉnh lr (CPU, 5 tiến trình song song): 2,3 giờ thời gian thực; mở rộng lưới ở các ô đầu mút: 0,8 giờ.
- Code gốc LTSF-Linear với `drop_last` bật và tắt (GPU, tổng thời gian của các lần chạy): 2,6 giờ.
- Huber với δ theo bước, 2 ô (GPU): 3 phút.

D.5. Phiên bản

Các bảng, hình và số trong báo cáo được sinh từ `results/` ở commit `d3c31e2` (commit cuối cùng thay đổi `results/`). Mỗi dòng trong các file `lambda_path.csv` và mỗi JSON của SGD ghi commit đã sinh ra nó (cột `git_commit`). LTSF-Linear được ghim ở commit `0c11366` qua git submodule.